

오토인코더 모델과 이미지 감산 기법을 활용한 비지도 PCB 불량 검출 시스템

김지송¹, 박지수², 김정석¹

¹가천대학교 보건과학대학 의용생체공학과, ²가천융합의과학원

e-mail: kjsong1028@bme.gachon.ac.kr, jspark@bme.gachon.ac.kr, hyunchul@berkeley.edu,
jungsuk@gachon.ac.kr

The unsupervised learning in PCB defect detection
Using Autoencoder model and the image subtraction method

Ji-Song Kim¹, Ji-Su Park², Jung-Suk Kim¹

¹Department of Biomedical Engineering, Gachon University, 191 Hambakmoe-ro, Incheon, 406-799.

²Department of Health Science and Technology, GAIHST, 21999, Incheon, Korea

Abstract

본 논문은 공정상의 검사자 육안검사와 머신비전 및 딥러닝 CNN 기반 불량 검출 시스템으로 제안되었던 방식의 단점을 개선할 수 있도록 오토인코더를 이용한 PCB 불량 검출 방법을 제안한다. 이 방식은 검사자의 숙련도 및 피로도에 영향을 받는 육안검사 방식의 단점을 해결하며, 검사영상의 불량 여부를 판단한 레이블 데이터를 모두 필요로 하는 CNN 방식의 단점을 해결한다. 본 논문에서 제시한 오토인코더를 이용한 PCB 불량 검출 방법은 불량 검사 영상을 입력으로 받아 정상 영상으로 출력시키도록 모델을 학습시킨 후, 입력 영상과 출력 영상의 감산 결과를 통해 불량 여부를 판단한다. 데이터 불균형 및 모델 성능 향상을 위해 이미지 증강기법을 실험에 사용한 데이터에 적용했다. 실험은 오토인코더 구조와 적용한 결점의 종류 및 데이터 증강 기법의 종류에 따라 감산 이미지의 결과를 비교했으며, 다양한 노이즈 및 필터를 적용한 입력 영상에서도 skip-connection을 적용한 오토인코더 구조에서 가장 좋은 결과를 보였다.

I. Introduction

현재 PCB 생산 라인에서는 공정상의 검사자 육안검사와 머신비전기반 불량 검출 시스템을 사용한다. 공정상의 검

사자 육안검사는 생산라인에서 작업자가 직접 현미경 등을 이용하여 결점을 분류하는 방식이다. 위 방식은 작업자의 숙련도와 작업피로도에 따라 검출 성능이 저하된다는 단점을 가지고 있다. 이러한 문제를 해결하기 위해 최근에는 머신비전기반 불량 검출 시스템으로 딥러닝 지도학습 방법론 중 하나인 CNN[2, 5]을 이용한 불량 검출 방식[1]이 제시되었다. 위 방식은 입력 데이터와 입력 데이터에 대한 명시적인 정답을 이용하여 딥러닝을 진행한다. 그러나 이러한 조건은 실제 산업에서 적용시키기 어려운데, 이는 PCB 생산과정 중 발생할 수 있는 모든 결함을 관찰하고 그에 대한 명시적인 정답을 모두 적용해야하기 때문이다. 따라서 실제 산업환경에 적용하기 위해서는 이를 개선하기 위한 방법이 필요하다.

본 논문에서는 위와 같은 상황을 개선하기 위해 딥러닝 비지도학습 방법론 중 하나인 오토인코더[3, 4, 5]를 이용하여 명시적인 정답 적용 없이도 PCB 불량 검출을 진행하는 방법을 제안하고자 한다.

II. Method

2.1 데이터

본 연구에 적용된 원본 영상은 800x503 해상도를 가진 PCB 영상 10장을 사용했다. 원본 영상의 예는 Fig.1과 같이 제시된다. 영상은 먼저 PCB 양품 데이터 셋을 구성하기 위해 원본 영상을 200x200 해상도를 가지도록 42개의 영상으로 분할하여, 총 420개의 양품 데이터셋을 구성했다. 또, 불

량 데이터 셋을 구성하기 위해 양품 영상의 임의의 위치에 결점을 적용하였으며, 결점의 강도를 세 단계(검정색: (0,0,0), 진한 회색: (127,127,127), 옅은 회색: (195,195,195))를 적용하여 총 1260개의 영상을 만들었다. 해당 결점을 적용한 영상의 예는 Fig. 2와 같다.




Fig. 1 PCB 영상(800x503)




Fig. 2 왼쪽상단) 원본 영상, 우측상단) 검정색 불량, 왼쪽하단)진한 회색 불량, 우측하단) 옅은 회색 불량

2.2 데이터 증강기법

데이터 불균형 및 모델 성능 향상을 위해 데이터셋에 이미지 증강기법을 적용했다.[6] 또한, 공정상에서 발생하는 요소를 반영하기 위해 다음과 같은 방법들을 선택했다. 먼저 실제 공정상의 미세한 움직임으로 인한 오차를 반영하기 위해 x축 및 y축 이동("x":(-10,10), "y":(-10,10))과 미세 회전(-1°,1°)을 적용했다. 그 다음 PCB를 제조 공정에서 검사 장비로 촬영했을 때 발생할 수 있는 노이즈를 반영하기 위해 가우시안 노이즈와 페퍼 노이즈를 적용했다. 해당 영상은 Fig.3과 같다. 위와 같은 과정을 통해 하나의 PCB 영상당 5625개의 증강 데이터를 생성하였고, 총 56250개의 영상을 만들었다.




Fig. 3 왼쪽) 가우시안 노이즈를 추가한 불량 데이터, 오른쪽) 페퍼 노이즈를 추가한 불량 데이터

2.3 오토인코더

오토인코더는 입력층의 노드 수와 출력층의 노드 수를 같게 만드는 신경망으로, 은닉층의 노드 수가 입력층이나 출력층의 노드 수보다 적은 것이 특징이다. 이러한 구조는 입력 데이터의 특징을 압축하며, 이는 노이즈 제거에도 효과적이라고 알려져 있다.




Fig. 4 좌측) 최외각 skip connection이 없는 오토인코더 구조, 이하 모델 1 우측) 최외각 skip connection을 추가한 오토인코더 구조, 이하 모델 2

본 연구에서 비교하는 오토인코더는 Fig. 4와 같다. 좌측 모델(이하 모델1)은 최외각 skip connection이 없는 오토인코더 구조이며, 우측 모델(이하 모델2)은 최외각 skip connection을 추가한 오토인코더 구조이다. 위 두 모델을 이용하여 성능 차이를 비교하였다.

2.4 시스템 구성




Fig. 5 시스템 구성

이 연구에서 제안하는 전체 시스템 구성은 Fig. 5와 같다. 먼저, 학습 및 테스트 데이터로 사용할 PCB 영상에 전처리를 진행한다. 다음으로 사용할 오토인코더 구조를 정의한 후, 입력 영상에서 결점을 제거하도록 학습시킨다. 마지막으로 테스트 데이터와 모델이 생성한 결점 제거 영상에 이미지 감산 기법을 적용해 불량 여부를 구분한다.

III. Result

오토인코더의 학습 및 테스트는 8700K, GTX 1080ti GPU로 구성된 시스템에서 진행했다. 모델의 성능 비교는 노이즈가 없는 불량 데이터셋(Fig. 6), 가우시안 노이즈를 추가한 불량 데이터셋(Fig. 7), 페퍼 노이즈를 추가한 불량 데이터셋(Fig. 8) 총 세가지 데이터 셋으로 진행하였다. 각각의 결과에서 첫번째 줄은 모델1, 두번째 줄은 모델2의 결과를 나타낸다. Input은 모델에 입력되는 영상, Output은 모델의

결과값으로 나온 영상, Delta는 $(x_output/\max(x_output) - x_input/\max(x_input))$ 한 값, 마지막 그래프는 Delta값을 flatten한 그래프다.

먼저 노이즈가 없는 불량 데이터 셋을 이용하여 모델1과 모델2의 성능을 비교하였다. Fig. 6에서, 검정색 불량에서는 큰 차이가 보이지 않았다. 그러나 진한 회색, 옅은 회색 불량에서는 그래프에서 확인 했을 때 모델2가 모델1에 비해 성능이 좋았다.

두번째로 가우시안 노이즈를 추가한 불량 데이터셋을 이용하여 모델1과 모델2의 성능을 비교하였다. Fig. 7에서, 검정색, 진한 회색 불량 모두 그래프에서 확인 했을 때 모델2가 모델1에 비해 성능이 좋았다.

마지막으로 페퍼 노이즈를 추가한 불량 데이터셋을 이용하여 모델1과 모델2의 성능을 비교하였다. Fig. 8에서, 검정색, 진한 회색 불량 모두 그래프에서 확인 했을 때 모델2가 모델1에 비해 성능이 좋았다.

종합하면, 모델2가 모델1보다 더 선명하게 결정이 제거되었다. 또한, 각종 유형의 명시적인 정답 없이도 감산 기법을 이용하여 좋은 성능을 보였다고 할 수 있다.

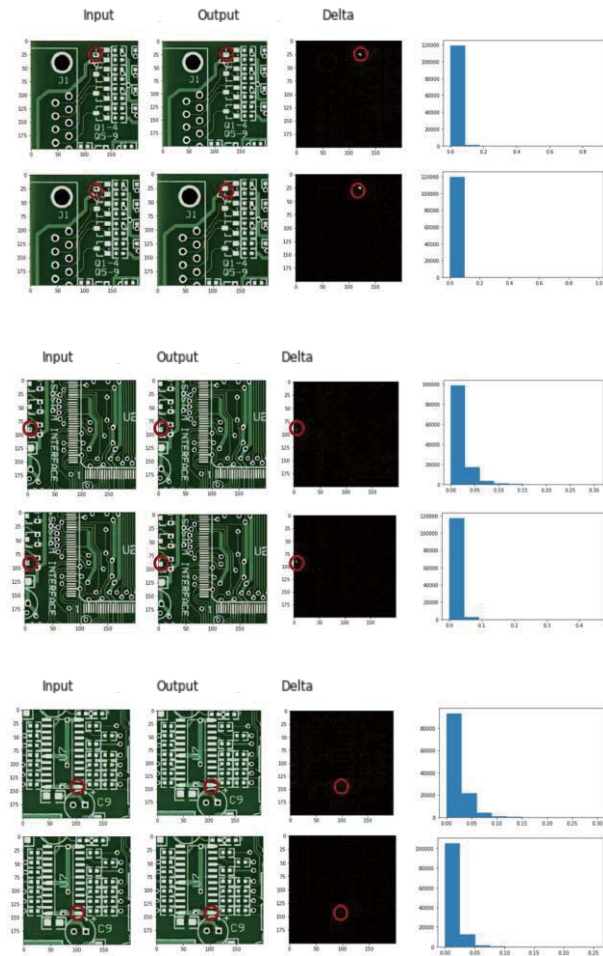


Fig. 7 노이즈가 없는 불량 데이터셋을 이용하여 모델1, 모델2 성능 비교; 불량 데이터셋은 차례로 검정색, 진한 회색 불량 사용됨

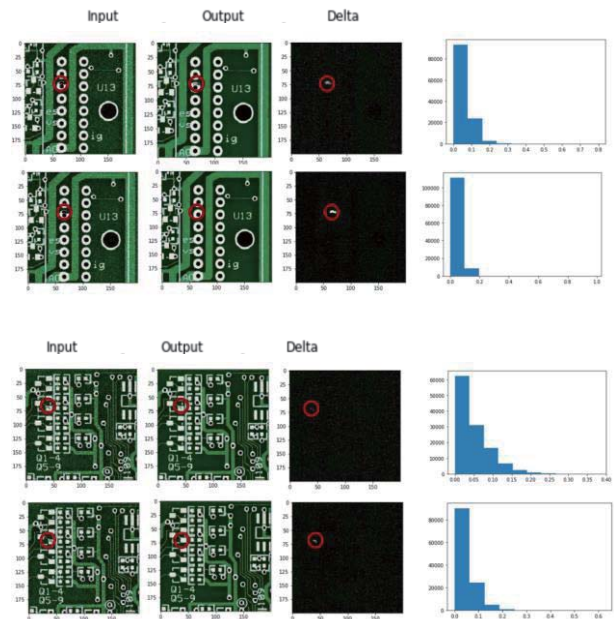


Fig. 7 가우시안 노이즈를 적용한 불량 데이터를 이용하여 모델1, 모델2 성능 비교; 불량 데이터셋은 차례로 검정색, 진한 회색 불량 사용됨

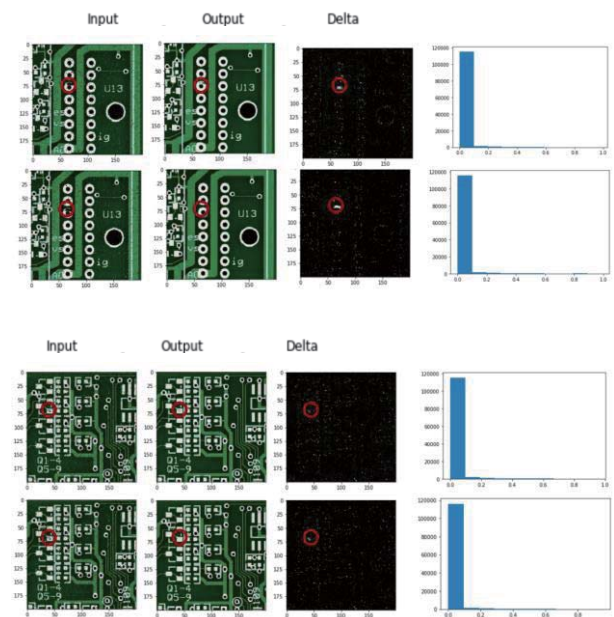


Fig. 8 페퍼 노이즈를 추가한 불량 데이터를 이용하여 모델1, 모델2 성능 비교; 불량 데이터셋은 차례로 검정색, 진한 회색 불량이 사용됨

IV. Conclusion

본 논문은 검사자의 육안검사 방식, 머신비전 및 딥러닝 CNN 기반 자동 결점 검출의 제한사항 해결방안을 목표로 진행했다.

위 결과를 통하여 최외각 skip connection을 추가 했을 때 CNN과 달리 모든 결함을 관찰하고 그에 따른 명시적인 정답을 기록하지 않아도 좋은 성능을 보인다는 것을 확인했다. 이는 공정상의 검사자 육안검사의 단점과 CNN을 이용한 방식의 단점을 개선했다는 것을 보여준다.

V. 참고문헌

- [1] V. A. Adibhatla, J. Shieh, M. F. Abbod, H. Chih, C. C. Hsu and J. Cheng, "Detecting Defects in PCB using Deep Learning via Convolution Neural Networks," 2018 13th International Microsystems, Packaging, Assembly and Circuits Technology Conference (IMPACT), Taipei, Taiwan, 2018, pp. 202-205, doi: 10.1109/IMPACT.2018.8625828.
- [2] P. Wei, C. Liu, M. Liu, Y. Gao and H. Liu, "CNN-based reference comparison method for classifying bare PCB defects," in The Journal of Engineering, vol. 2018, no. 16, pp. 1528-1533, 11 2018, doi: 10.1049/joe.2018.8271.
- [3] G.E Hinton, S. Osindero, and Y.W. Teh. A fast learning algorithm for deep belief nets. Neural computation, 18(7):1527–1554, 2006.
- [4] Hinton, G.E. and Salakhutdinov, R.R. Reducing the dimensionality of data with neural networks. Science, 313 (5786):504–507, 2006.
- [5] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. Deep Learning. MIT Press, 2016.
- [6] Shorten, C., Khoshgoftaar, T.M. A survey on Image Data Augmentation for Deep Learning. J Big Data 6, 60 (2019).