



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

인공지능을 이용한 인쇄 회로
기판 검사방법에 관한 연구
A study on the printed circuit board
inspection method using artificial
intelligence

한국공학대학교 일반대학원

컴퓨터공학과(전공)

김 지 훈

인공지능을 이용한 인쇄 회로
기판 검사방법에 관한 연구
A study on the printed circuit board
inspection method using artificial
intelligence

한국공학대학교 일반대학원

컴퓨터공학과(컴퓨터공학)

김 지 훈

인공지능을 이용한 인쇄 회로 기판 검사방법에 관한 연구

지도교수 배 유 석

이 논문을 석사학위 청구논문으로
제출함.

2022년 12월

한국공학대학교 일반대학원

컴퓨터공학과(컴퓨터공학)

김 지 훈

김지훈의 석사학위 논문을 인준함

심사위원장 정 두 희 인

심 사 위 원 최 중 필 인

심 사 위 원 배 유 석 인

한국공학대학교 일반대학원

2022년 12월

목 차

표 목 차	i
그림목차	ii
국문요약	iv
 I. 서론	 1
 II. 배경 및 관련 연구	 5
제 1 절 PCB 기판의 제작공정	6
1. PCB 기판의 제작공정	6
2. PCB 기판의 검사	8
2.1. PCB 기판 결함의 정의	8
2.2. PCB 기판의 주요 결함	8
2.3. PCB 기판 검사 방법 및 규격	9
2.4. 도체표면 규격(KS C6460)	10
2.5. 도체패턴 규격(KS C6460)	10
제 2 절 PCB 기판의 자동 비전 검사	11
1. PCB 기판 제작공정의 비전 검사 관련 연구	11
2. AFVI(Auto Final Visual Inspection) 장비	12
제 3 절 인공지능(AI, Artificial Intelligence) 모델	14
1. PCB 제조 분야의 딥러닝 기술 적용	14
2. 딥러닝 기반 기술	14
3. 합성곱 신경망(CNN)	16
4. Region-based CNN	19
5. Fast R-CNN	19
6. YOLO v3	20
 III. 시스템 설계	 23
제 1 절 PCB 인공지능 검사 시스템 설계	23
1. 제안 시스템 구성도	23
2. 제안 시스템의 작동순서	24
3. 제안 시스템의 결함 검사 대상	25
제 2 절 결함 검사 딥러닝 모델 설계	26
1. 학습 데이터 구성	28
2. 데이터 수집 방법	29
3. 데이터 라벨링	31

4. 딥러닝 모델	31
4.1. 딥러닝 모델 구조	31
4.2. 딥러닝 모델 학습 및 수정	32
IV. 실험 및 평가	34
제 1 절 실험 데이터 구성 및 환경	34
1. 실험 데이터 구성	34
2. 실험환경 구성	34
3. 학습 및 검사과정	35
제 2 절 실험 결과 및 분석	36
1. 결합 객체 탐지 결과	36
2. YOLO V3 수행 결과	38
V. 결론 및 향후 과제	41
참고문헌	42
Abstract	45

표 목 차

표 1-1. 국내 인쇄회로기판(PCB) 시장 매출현황	4
표 2-1. PCB 패턴 결함의 명칭	9
표 4-1. 실험환경 하드웨어 구성	34
표 4-2. 실험환경 소프트웨어 구성	35
표 4-3. 실험환경 YOLO V3 학습 파라미터	35
표 4-4. FAST R-CNN과 YOLO V3의 속도 비교	39

그 립 목 차

그림 1-1. 인더스트리 4.0 - 트랜스포메이션 프로세스	3
그림 2-1. PCB 기판의 제작공정	7
그림 2-2. PCB 패턴 결함의 예	9
그림 2-3. 프린트 콘택트의 결함	10
그림 2-4. 도체의 결손	10
그림 2-5. AFVI의 검사 절차	11
그림 2-6. AFVI의 VRS를 통한 프로그램 예시	12
그림 2-7. AFVI의 전체 흐름도	13
그림 2-8. 딥러닝 기술 구분	15
그림 2-9. 딥러닝의 세 가지 기술적 요소	15
그림 2-10. 2차원 데이터에 대한 CNN 알고리즘 구조	17
그림 2-11. 1차원 데이터에 대한 CNN 알고리즘 구조	18
그림 2-12. Region-Convolutional Neural Network(R-CNN) System Overview	19
그림 2-13. Structures of Fast R-CNN and RPN	20
그림 2-14. YOLO Detection System	21
그림 2-15. 주요 객체탐지 모델의 성능과 연산시간 비교	22
그림 3-1. AFVI(자동 외관검사) 장비의 작동원리	23
그림 3-2. 제안 시스템의 작동순서 흐름도	24
그림 3-3. PCB 결함 예시 이미지	25
그림 3-4. 머신러닝 기법을 적용한 PCB 제안 AI 알고리즘	27
그림 3-5. 딥러닝 활용 시 예측 DATA	28
그림 3-6. 수집된 결함의 종류와 수	29
그림 3-7. VRS에서 수집한 원본 이미지	30
그림 3-8. VRS 원본 이미지 전처리 과정	30
그림 3-9. 라벨링 도구를 사용한 예	31
그림 3-10. YOLO V3 경계박스(bounding-box) 처리과정	32
그림 3-11. YOLO V3 객체탐지 결과	32
그림 3-12. 재분류한 핀홀(pin hole) 결함 이미지	33
그림 4-1. 객체 탐지 모델의 성능을 시각적으로 확인한 결과	36

그림 4-2. 단계별 객체 탐지 모델의 성능을 시각적으로 확인한 결과	37
그림 4-3. 재분류한 예측 및 검증 결과	38
그림 4-4. FAST R-CNN과 YOLO V3의 검출 결과 비교	38
그림 4-5. 객체탐지 과적합 발생 결과	39
그림 4-6. 보강된 객체의 탐지 결과	40

국문 요약

최근 산업체에서 사용되고 있는 최종 외관검사 장비(AFVI, Auto Final Visual Inspection)는 품질 관리를 강화하기 위해 도입 설치하여 가동 중이나 그 성능을 충분히 사용하지 못하고 있으며, 데이터의 체계적인 축적과 분석이 미흡하다. 또한 추출된 영상의 이미지들은 분석하는 데는 다른 프로그램(VRS)을 통해서 재확인 작업해야하는 등 많은 시간이 소요되며, 눈으로 확인하는 작업일 경우 완전무결함의 제품을 찾는 것은 현실적으로 불가능하다.

본 연구에서 인공지능을 이용한 인쇄회로기판(PCB, Printed Circuit Board, 이하 PCB)의 최종 검사과정에 반복적인 검사를 줄이고, 불량 이미지에 따라 라벨링 된 결함의 특성을 고려하여 적합한 인공지능 알고리즘인 YOLO V3를 이용하였다. 이는 객체(object)가 시야 안에 있을 때 바로 판단하는 사람의 시각 기관(human visual system)과 유사하도록 모델을 단일 신경망(single neural network)으로 구성되어 있어 지도학습을 수행하면서 판정된 이미지들은 더욱 신뢰성 있는 검사 방법이 될 것이며 또한 검사원의 의사결정에 중요한 지표가 될 것이다.

인공지능을 이용하여 분석한 ‘사용자(고객)가 원하는 제품’ (협이가 끝났거나 표준규격에 정해진 제품), 즉 선별된 제품은 최종 검사장비에서 작업하는 검사원의 반복 작업을 줄임으로써, 제조시간을 단축하고, 납기에 대한 경쟁력을 갖출 수 있다. 학습된 데이터 중 자주 검출된 제품들의 불량 이미지들은 데이터를 저장하여, 불량 이미지를 객체 탐색하여 집중적으로 품질 이슈를 통해 불량 재작업 비용을 감소시키고 품질 수준이 향상될 수 있다.

I. 서론

최근 인쇄회로기판(PCB, Printed Circuit Board, 이하 PCB)을 제조하는 산업체에서 스마트공장 보급·확산을 통해 PCB 제조설비에 SCM^{주1)}(Supply Chain Management)을 개발하고, MES^{주2)}(Manufacturing Execution System)를 구축하였다. PCB 기판 제조 작업의 특성상 전 과정 작업을 사내에서 모두 수행하기는 불가능하다. (전 과정을 내부에서 자체적으로 수행하기 위해서는 많은 투자가 수반되어야 한다) 따라서 외주 업체들과 많은 부분의 협력이 필요하다. 제작 과정 중 중간 제품이 외주 업체로 이동하여 작업 후 다시 자사로 이동하는 일련의 작업은 간단히 소개하기로 한다. 작업하는 과정들이 되풀이되기도 하고 제조 중간 단계에 있는 중간 제품의 물류 및 품질 관리가 매우 중요한 부분으로 작용한다.

또한 인더스트리 4.0과 같은 지능형 공장에서 인공지능, 데이터 기반 업무 고도화, 첨단설비 융합 활용 등 생산성 향상과 부가가치 고도화를 위해서 기업의 제품 특성, 공정 구성, 협력 업체와 협업 능력, 요구하는 품질 수준 등을 파악하여 구체적이고 단계적인 목표를 정하고 우선순위를 정하여 지속이 가능한 업무 향상이 될 수 있도록 데이터가 축적되어야 한다. 이러한 연구는 인더스트리 4.0에 도약하기 위한 기반으로 담당자의 높은 업무 파악 능력과 적극적인 참여가 핵심이며 제시된 프로젝트가 체계적으로 실행되고 운영되기 위해서는 사람의 기술 능력과 업무 프로세스가 뒷받침되어야 한다.

본 연구에서는 인공지능을 이용하여 고객의 요구사항을 충분히 만족할 만한 출하 검사공정의 PCB 기판 검사 방법을 제안한다.

주1) SCM: 공급망 관리. 현재 PCB에 개발된 SCM은 협력사(외주)와의 생산과 유통과정을 하나의 통합망으로 관리하는 협업시스템 전략이다.

주2) MES: 환경의 실시간 모니터링, 제어, 물류 및 작업내용 추적 관리, 상태 파악, 불량 관리 등에 초점을 맞춘 현장 시스템이다.

1. 인더스트리 4.0 개념 정의

먼저, 인더스트리 4.0에 대한 개념부터 정의해 보도록 한다. 인더스트리 4.0 개념은 제4차 산업혁명을 의미하며, 이는 제품 라이프 사이클(전반)에 걸친 전체 가치 창출 사슬 조직과 관리의 새로운 단계이다. 이러한 라이프 사이클은 점점 더 개인화된 고객의 요구사항에 맞추며 아이디어, 개발과 제조에 대한 주문, 최종 고객에게 전달 및 리사이클링까지 그리고 그러한 것들과 연계된 서비스까지 확대된다. 기반은 모든 가치 창출에 관여하는 조직의 네트워킹을 통한 모든 중요한 정보의 실시간 가용성 및 데이터로부터 언제든지 최적의 가치 창출 흐름을 도출할 수 있는 능력이다. 인간, 객체(대상물) 및 시스템의 연계를 통해 다이내믹하고 실시간으로 최적화되고 자율적으로 조직하는 범 기업적인 가치 창출 네트워크가 만들어지며, 이는 예를 들어 비용, 가능성 그리고 자원 소비와 같은 다양한 요인이 최적화 되도록 한다.[1]

2. 인더스트리 4.0 양면 전략

기업은 주요 목표는 이익을 극대화하는 것. 다시 말하면 효율적인 제조를 위해선 품질향상과 원가절감 그리고 제조의 리드타임을 단축하는 것이다. 또한, 제조 기술을 통해 효율적이고 경쟁력을 확보할 수 있다면 고객의 맞춤형 주문 생산이 가능하다.

공산품 제조를 인더스트리 4.0으로 전환하기 위해 독일에서는 양면 전략을 구사해야 한다. 독일 설비산업(Equipment industry)은 전통적인 첨단기술과 함께 정보통신기술(ICT, Information and Communication Technologies)의 지속적인 통합을 통해 지능형 제조 기술의 선도 공급자가 됨으로써 계속해서 세계 시장에서 선도적으로 머물러야 한다. CPS(Cyber Physical System) 기술과 제품의 새

로운 선도적인 시장은 만들어지고 관리되어야 한다. 동시에 독일에서 제조 (Manufacturing)는 효율적이고 자원을 절감하는 제조 기술을 통해 매력적이고 경쟁력을 확보할 수 있도록 계속해서 발전되어야 한다. 목표는 독일 기업의 경쟁우위 확대이며, 이는 인터넷을 통해 공간적으로 가깝고 이용자와 생산자의 적극적인 네트워킹을 통해 창출된다. 독일의 자동화, 프로세스 그리고 제조 기술은 이러한 전략을 통해 마찬가지로 이익을 본다.[2]

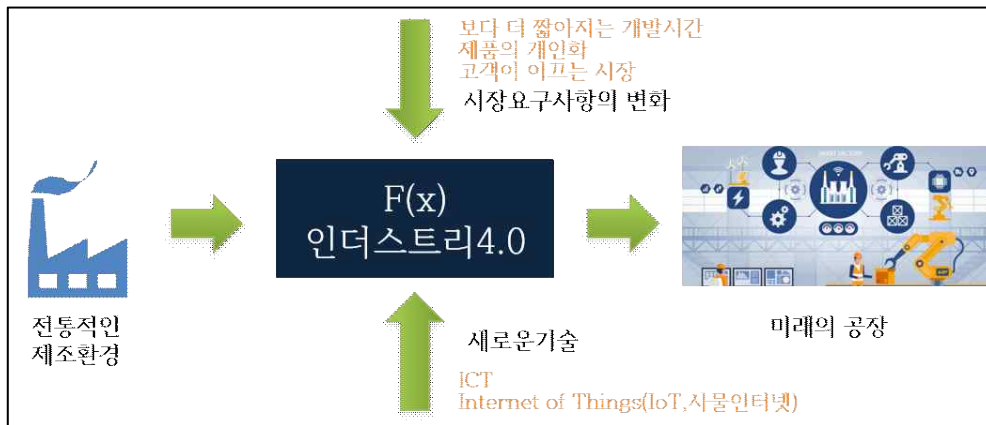


그림 1-1. 인더스트리 4.0 - 트랜스포메이션 프로세스

3. 국내 PCB 시장 동향

스마트폰 시장은 주(빌드업, HDI)기판과 연성 PCB기판 수요가 줄었으며 2분기에는 가격 인하 및 원자재 인상으로 업체 경영 상황이 악화될 수 있다고 예상하고 있으며 하반기실적은 5G 스마트폰 출시와 소비 증가에 따른 인프라 구축으로 전년 동기보다 실적이 증가 될 것으로 예상된다. 현재 자동차 기판이 주력으로 하는 산업체는 물량 감소와 가격 하락을 동시에 겪고 있는 상황에서 전기차와 같은 친환경 차량의 기판 수요와 기술 난이도가 함께 올라가는 추세다. PCB기판의 설비 분야에서는 반도체 기판과 더불어 5G기판 투자가 이어지고 있

지만, 나머지 제품 분야의 투자는 감소하고 있는 실정이다. 소재 분야는 고부가가치 제품과 5G 저유전율 소재인 일본의 수입 대체품도 실적이 상승될 전망이다.

표 1-1. 국내 인쇄회로기판(PCB) 시장 매출현황

구분 (단위:억원)	2019년	2020년	2021년(전망)			성장률 (21년/20년)
			합계	상반기	하반기	
경성PCB	40,000	39,800	39,000	19,400	19,600	-2.0%
연성PCB	31,200	32,200	31,000	14,600	16,400	-3.7%
반도체 기판	27,800	33,000	38,600	19,000	19,600	17.0%
합계	99,000	105,000	108,600	53,000	55,600	3.4%

자료:KPCA 한국 PCB & 반도체 패키징 산업협회

하반기에는 PCB시장 규모가 반도체 기판을 중심으로 경·연성회로(RF-PCB)기판의 성장이 예상되며 경성과 연성 PCB 성격을 모두 갖춘 유기 발광 다이오드(OLED)패널 및 카메라 모듈 등에 주로 사용되는 경·연성회로(RF-PCB)기판이 성장세로 오를 전망이다. 3분기에는 애플의 아이폰이 신제품으로 출시되고, 아이폰의 OLED용 RF-PCB는 삼성전기와 BH, 영풍전자 등이 생산하고 있다. 지난 1분기에는 전체 PCB시장의 매출 규모가 전년보다 6.5% 성장했다. 삼성전자의 스마트폰 신제품 출시와 반도체 기판 수요는 긍정적인 영향을 미쳤다. 반면에 2분기는 성장세 둔화가 예상된다. KPCA는 2분기에는 시스템 반도체 수급 불안과 따른 베트남의 재고조정이 예상되는 상황에서 전체 매출은 전년보다 4.2% 증가할 것으로 예상된다.

고객의 요구사항을 반영하는 것은 최적의 가치 창출이며, 기업의 이윤을 극대화할 수 있다. PCB 제조뿐만 아니라, 다품종 소량생산을 전문으로 모든 산업체들은 제품을 더 효율적인 제조하는 것, 즉 품질을 향상시키고, 원가를 줄이며, 제조의 리드 타임을 단축하는 것이 궁극적인 목표라 할 수 있다. 앞단(인더스트리 4.0의 개념 정의와 양면 전략)에서 언급한 것과 같이 인더스트리 4.0의 핵심 목표와 걸맞게 제조를 최적화하기 위해서는 기계·설비에 지능형 네트워크를 구현하는 것은 필연적 요소라 볼 수 있다.

II. 배경 및 관련 연구

지능형 공장에서 인공지능, 데이터 기반 업무 고도화, 첨단설비 융합 활용 등에 대한 생산성 향상과 부가가치 고도화를 위해서 기업의 제품 특성, 공정 구성, 협력 업체와 협업 능력 등 높은 품질 수준을 파악하여 구체적이고 단계적인 목표로 설정하고, 지속할 수 있는 업무 향상이 될 수 있도록 데이터가 축적될 수 있는 알고리즘이 필요하다.

PCB 기판만의 검사 알고리즘으로 활용할 수 있으며, AFVI^{주3)} 장비의 활용도를 높여 반복 작업을 줄임으로써 품질 수준을 향상하고, 제조시간을 단축함으로써 납기에 대한 경쟁력을 확보할 수 있으며, 작업자에 따라서 장비 설정의 오차를 최소화하여 작업 준비시간을 단축할 수 있다. 또한 AFVI 장비의 반복 확인(CHECK) 작업을 줄여 검사원의 업무량을 감소시킬 수 있다. 최종적으로 이는 생산, 품질, 원가, 납기에 대한 소요를 줄여 제조원가를 낮추고 이익을 극대화할 수 있게 된다.

본 연구에서는 AFVI 장비를 효과적으로 사용하는 방법을 제시하여 인공지능을 활용하고, 결과를 데이터로 축적하여 제품 디자인과 제조공정의 피드백으로 활용할 수 있는 업무 프로세스를 제시한다. 이는 작업자가 다시 검사하는 불필요한 시간 낭비를 제거할 것이다. 이미지의 설정오차를 감소시키고 검사자의 숙련도와 관계없이 일정 결과 값이 나오도록 표준화할 것이며, 인공지능 알고리즘을 적용하여 설계와 제조 품질에 피드백하여 품질 지표가 향상될 것으로 기대한다. 또한 새로운 신제품 디자인에 활용되어 공정 업그레이드에 활용될 것이고, 누적된 DB 데이터는 새로운 제품의 디자인에 활용할 수 있을 것으로 예상된다.

주3) AFVI: 자동 검사장비. 고객이 요청한 거버 데이터(Gerber data)와 일치 여부를 판독하는 비주얼 검사장비다. 특히, 외관 품질을 확인한다. 이하 “자동검사장비”라 부른다.

제 1 절 PCB 기판의 제작공정

1. PCB 기판의 제작공정

PCB 기판 공정은 크게 12가지의 공정으로 이루어졌으며, CAM작업 ➡ 내층공정 ➡ 적층공정 ➡ 드릴공정 ➡ 도금공정 ➡ 외층공정 ➡ 인쇄공정 ➡ 표면처리공정 ➡ 외형가공 ➡ E-TEST ➡ 최종검사 ➡ 출하 등이 있다. PCB 기판 제조 작업의 특성상 전 과정 작업을 사내에서 모두 수행하기는 불가능하므로 외주 업체들과 많은 부분의 협력이 필요하다. 또한, 제작 과정 중 중간중간 제품이 외주 업체로 이동 작업 후 다시 자사로 이동하는 일련의 작업이 이루어짐으로써, 제조 중간 단계에 있는 중간 제품의 물류 및 품질 관리가 매우 중요한 부분으로 작용하고 있다.

최종 검사공정에서 AFVI 장비를 도입하여 외관검사를 진행하고 있는데, 이 장비의 특징을 살펴보면 설계된 도면(Gerber data)을 마스터링 작업하여, 실제 PCB 기판을 스캔한 카메라 영상과 비교 대조를 통해 양품과 불량을 판단하는 장비이다. 여기에서 문제점은 회로가 점차 복잡하고 집적화 되어 사람이 맨눈으로 검사하는 것에는 한계가 있다는 것이다. 참조 영상으로 확인하는 것은 많은 시간과 반복적인 확인 작업이 필요하고, 완전 무결함 제품을 찾는 게 거의 불가능하다.



그림 2-1. PCB 기판의 제작공정

2. PCB 기판의 검사

2.1. PCB 기판 결함의 정의

PCB 기판은 모든 전자 부품의 핵심이다. 모든 전자 장치의 원활한 작동을 확인한다. 따라서 PCB 기판에 경미한 오류가 발생하면, 장치가 자주 작동을 멈추게 된다. PCB 제조 과정에서 약간의 실수를 하면 PCB 문제가 극도로 심각하고 불가사의해질 수 있다. PCB 기판의 다양한 결함과 제조 및 조립 공정 중, 이러한 문제를 염두에 두고 가능한 한 이러한 결함(불량) 문제를 피하려고 노력해야 한다. 이러한 품질의 중요성 때문에 외관검사는 다음 공정인 표면 실장기술(SMT, Surface Mount Technology)인 반도체 부품과 접합 과정 중에 신뢰성을 저하하는 인자가 발생하므로 주의 깊게 관찰해야 한다. 즉, 외관 품질검사를 결함이 없는 깨끗한 상태로 검사해야 한다. 그중 중요한 부분이 반도체 부품과 결합하는 패드(pad) 부분은 표면이 매끄럽고, 긁힘, 찍힘, 흠 등이 없이 양호해야 한다.

2.2. PCB 기판의 주요 결함

전자 제품의 핵심 구성요소 중 하나인 PCB는 생산 과정에서 먼지나 낡은 필름, 과부식 등에 의해 결함이 발생할 수 있다. 또한 PCB 패턴은 구리로 구성되어 있어 쉽게 손상을 입을 수 있고 변색할 수 있다. PCB의 결함은 크게 세 가지 유형으로 분류할 수 있다. 첫째, PCB의 배선에 발생하는 결함으로 배선의 패임(mouse bite), 일률적인 수축(over-etching), 단락(open), 내부상의 흠(pin-hole) 등의 결함이 있다. 둘째, 절연체 영역(insulator region)에 발생하는 결함으로 도선 돌출(spur), 배선의 일률적인 팽창(under-etching), 배선 사이의 연결(short) 등의 결함이 있다. 셋째, 홀과 패드에 해당하는 결함으로 홀이나 패드의 크기 및 위치에 따른 결함이 있다. 이외에는 긁힘(scratch), 이물질(foreign particles)로 인해 발생하는 결함들이

있다. [그림 2-2]는 결함의 형상으로 (a)는 결함이 없는 PCB 패턴이며 (b)는 결함이 발생한 모습이다. [표 2-1]은 각 결함의 명칭이다[3]




그림 2-2. PCB 패턴과 결함 부위

표 2-1. PCB 패턴 결함의 명칭

1	Breakout	7	Pinhole
2	Missing hole	8	Missing conductor
3	Under-etching	9	Over-etching
4	Wrong size hole	10	Short
5	Mousebite	11	Open circuit
6	Spurious copper	12	Spur

2.3. PCB 기판 검사 방법 및 규격

PCB 기판의 검사규격인 IPC 6012C 나 IPC 600(L)은 국제표준 검사규격으로 결함이 없는 상태를 말한다. 하지만, 국내에서는 별도로 KS C 6460(KS) 규격으로 사용자(고객)와 협의해서 진행하기도 한다. 여기에서 국내규격(KS)은 다층배선 기판이라 불리며, 표면을 ‘겉모양’으로 칭한다. 적용 범위로는 이 규격은 주로 전자기기에 사용하는 다층 프린트 배선판(이하 프린트판이라 한다)에 대하여 규정한다. 다음에서는 PCB 기판의 외관검사에 필요한 규격만 간략히 소개하고자 한다.

2.4. 도체표면 규격(KS C6460)

도체표면에는 부품, 주름, 균열, 도체의 땀, 벗겨짐 및 도체의 끝에서 떨어져 걸린 금속조각이 없고, 실용상 해로운 요철, 흠, 녹 및 때린 흔적이 없어야 한다. 도체 표면 및 도금 관통구멍 내에 실용상 해로운 변색, 오염 및 이물의 부착이 없어야 한다. 또, 땀납 도금 또는 땀납 코팅을 한 인쇄판에는 바탕인 구리의 노출이 없어야 한다.

동박 제거면은 표면이 매끄럽고, 부품, 갈라진 곳이 없어야 한다. 또, 실용상 해로운 먼지, 색 얼룩, 흠, 요철 및 줄무늬 모양이 없어야 한다.




그림 2-3. 프린트 콘택트의 결함

2.5. 도체패턴 규격(KS C6460)

도체의 결손 도체 패턴의 [그림 2-3] 와 같은 결손 부분의 너비(w)는 도체 너비의 20% 이하이고, 또한 0.5mm 이하여야 한다. 또한, 결손 부분의 길이(l)는 도체 너비 이하이고 또한, 5mm를 초과해서는 안 된다.




그림 2-4. 도체의 결손

제 2 절 PCB 기판의 자동 비전 검사

1. PCB 기판 제작공정의 비전 검사 관련 연구

제조 공정중에 발생하는 PCB기판상의 도체(패턴) 결함은 회로를 형성하는 에칭 공정과 회로를 보호하는 인쇄공정에 있다. 그 결함의 종류는 다양하다. PCB 기판상에서 나타나는 결함들은 크게 편의상 동박 노출면(패드)의 경계면에 나타나는 결함과 내부 또는 외부에 나타나는 결함들로 구분된다. 패드의 윤곽선 주위에 나타나는 결함으로는 Open, Short, Nick, Protrusion, missing conductor 들이고, 그 외의 결함은 패드 내부 또는 외부에 발생하는 결함들이다.

본 연구에서는 패드의 윤곽선 주위에 발생하는 결함과 패드 안쪽에 발생하는 변색, 이물질에 대해서 신뢰성 있게 검사하는 방법을 제시하고자 한다. 제안한 방법은 CAM 마스터 참조 영상, 즉 AFVI(자동외관검사)장비로 부터 패드의 윤곽선(contour), 정점(vertex) 등의 정보와 필터 설계를 통하여 영상을 검사하여 결함들을 추출하게 된다. [그림 2-5]는 전체적인 검사 절차이다.[4]

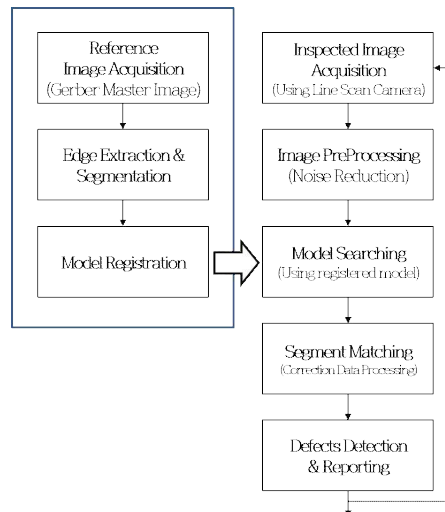


그림 2-5. AFVI의 검사 절차




그림 2-6. AFVI의 VRS를 통한 프로그램 예시

AFVI(자동외관검사) 장비로 부터 검사 절차에 따라 VRS(검사프로그램)를 통해 검사영역을 [그림 2-6]에 나타낸다. 왼쪽 (a) 그림은 기준이 되는 추출된 마스터(참조)영상을 나타내고 있고, 오른쪽 (b)는 결함위치를 포함한 영역을 영상으로 나타낸다. 결함의 발생 부분 (a)의 흰 박스는 □ 표시로 결함 위치를 검사자가 육안으로 쉽게 파악할 수 있도록 표시되어 있다.

2. AFVI(Auto Final Vision Inspection) 장비

PCB기판의 최종 검사공정은 육안이나 확대경을 이용하여 제품의 특성과 특히 외관검사를 확인하는 공정으로써, 검사장비(AFVI, Auto Final Visual Inspection)를 이용한 검사 방법을 간략하게 소개하기로 한다.

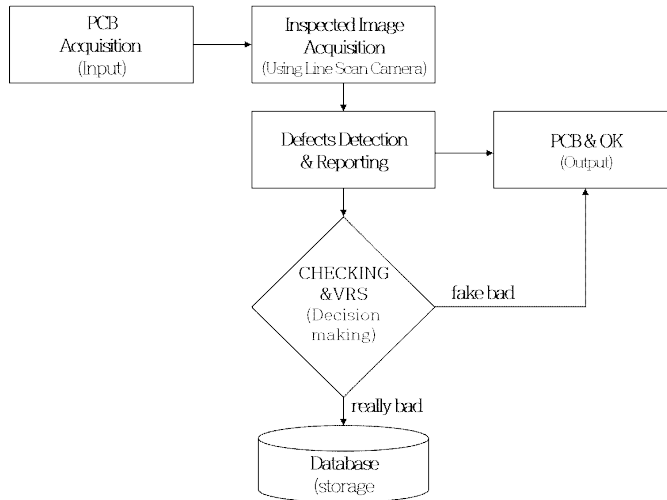


그림 2-7. AFVI의 전체 흐름도

검사하고자 하는 PCB 기판을 왼쪽 로더 부분에 적재하여 우측에서 양품과 체크로 분류되어 배출된다. 참조 영상과 비교하여 비정상적인 제품을 선별하여 VRS(Verify Rework Station)로 검사 이미지를 전송한다. 이때 분류된 체크 이미지는 진짜 불량과 가짜 불량이 혼입되어 있기에 검사자가 판단(의사결정)하여 재확인해야 한다. 완전무결한 제품을 찾는 것은 거의 불가능하므로, 의사결정 지원 알고리즘을 개발하여 AI 검사판정 지원 데이터 처리를 가능하게 해야 한다. 또한, 기존의 체크로 인식된 제품의 재검 시간 낭비 개선하기 위해서 실시간 서버의 일괄처리를 모듈화 시켜 재검사에 따른 인력 낭비를 최소화해야 한다.

마지막으로, 데이터를 분류하기 위한 기준의 알고리즘이 없으므로 수집 데이터에서 변화량 기준의 중요도 선정 알고리즘을 설계하여, 처리데이터가 중요도에 따라 할당 가능해지도록 한다.

제 3 절 인공지능(AI, Artificial Intelligence) 모델

1. PCB 제조 분야의 딥러닝 기술 적용

PCB 관련 OCR(Optical Character Recognition) 연구 및 부품 조립 불량 검사 분야로 PCB 불량 검사와 관련해서는 생산업이 국가 주요 산업인 동남아시아 및 중국, 국내에서 연구가 주로 이루어지고 있다. 특히 이미 다른 연구 분야에서 딥러닝을 활발하게 사용하기 시작했던 시기인 2010년대 중반에는 PCB 분야에서 그다지 연구되지 않았으나, 이후 최근 3년 정도 딥러닝이 활발하게 이용된 것으로 보인다. PCB 분야 특성상 데이터베이스 수집이 힘들고, 데이터베이스를 확보한다고 해도 데이터 자체가 대외비인 경우 등 다양한 이유로 연구가 제한되기 때문에, 여러 연구에서는 PCB 생산 설비가 있는 기업에서 연구논문을 작성하는 예도 종종 보인다.[5][6]

2. 딥러닝 기반 기술

딥러닝은 분류에 사용할 데이터를 스스로 학습하여 적용하는 머신러닝의 대표적인 방법론 중 하나인 지도학습과 비지도학습 그리고 강화학습을 이용하는 기술이 있다. 본 연구에서 제안한 검사 방법은 지도학습을 사용하여 PCB 결함을 검출하고 분류한다.

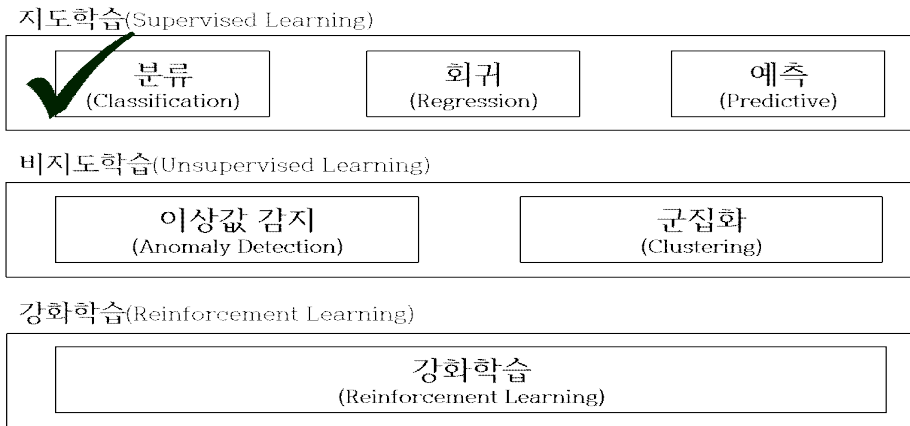


그림 2-8. 딥러닝 기술 구분

딥러닝을 이용한 고급기술을 통해 기존 검사의 알고리즘 성능을 크게 향상할 수 있으며, 높은 정확성을 가질 수 있는 이유는 아래 그림과 같이 세 가지 기술적 요소를 포함하고 있기에 가능해지는 것이다.



그림 2-9. 딥러닝의 세 가지 기술적 요소

정지영상 또는 동영상에서의 객체 검출(Object Detection)은 영상처리와 컴퓨터 비전 분야에서 기본적인면서 많이 활용되는 기술 중 하나이다[7]. 객체 검출 알고리즘에서는 주요 객체를 탐지하고 해당 객체를 중심으로 경계 상자(Bounding Box)를 표시하여 구분한다.[8] 초기의 객체 검출 기술은 SIFT(Scale Invariant Feature Transform)[9], SURF(Speeded-Up Robust Feature)[10],

HOG(Histogram of Oriented Gradients)[11] 기법과 같이 객체가 갖는 특징을 설계하고 검출하는 방법을 주로 사용하였으며[12], 인식을 향상을 위해 SVM(Support Vector Machine)과 같은 기계 학습 방법을 적용한 연구도 있었다.[13][14] Alex의 논문[15]에서는 합성곱 신경망(CNN)을 적용한 딥러닝(Deep Learning) 기반의 객체 인식을 통해 기존 방식의 성능을 개선하는 방법을 제안하였다.

본 연구에서는 합성곱 신경망(CNN)과 그 계열에서 후보영역 탐지의 문제점을 개선한 YOLO 계열의 알고리즘을 살펴보고, 검출한 결합영역의 정확도와 속도 측면에서 비교될만한 대표적인 알고리즘인 YOLO와 Fast R-CNN 알고리즘을 적용하여 성능을 비교하여 살펴본다.

3. 합성곱 신경망(CNN)

DNN(Deep Neural Network)은 컴퓨터 비전, 음성 인식 등의 여러 패턴 인식 문제를 해결하기 위한 좋은 모델이다. 여기서 핵심적인 네트워크 모델 중 하나는 CNN(Convolutional Neural Network)이다. CNN은 격자 형태로 배열된 데이터를 처리하는 것에 특화되어 데이터의 패턴을 식별에 대하여 효과적인 신경망이다. 따라서 CNN은 공유 파라미터로 사용할 수 있는 다수의 필터를 활용하여 2차원의 경우 이미지의 공간 정보를 유지하며 인접 이미지와의 특징을 효과적으로 추출하며 학습한다. CNN은 최소한의 파라미터와 전처리 과정을 통해 더욱 간편한 학습을 가능하게 하는 장점이 있다. 다음은 CNN의 입력 데이터에 따른 출력값의 수식이다.[16]

$$s(t) = (x * w)(t) = \sum x(a)w(t-a) \quad \text{[수식 1]}$$

$$s(i,j) = (I * K)(i,j) = \sum_m \sum_n I(m,n)K(i-m,j-n) \quad \text{[수식 2]}$$

위 수식은 1차원 데이터에 대한 합성곱 계층의 출력 수식이다. x 는 입력 데이터값이고, w 는 kernel map이다. 여기에서 $s(t)$ 는 출력 계층인 피쳐맵(feature map)이다. [수식 2]는 2차원 입력 데이터 값에 대한 합성곱 계층의 출력 수식이다. I 는 입력 데이터값이며, K 는 kernel map, $s(i,j)$ 는 출력 계층인 2차원 피쳐맵(feature map)이다. 아래 그림은 2차원 입력 데이터에 대한 CNN 알고리즘의 구조도이다. [그림 2-10]을 살펴보면 CNN 알고리즘은 네 단계로 구성된다.




그림 2-10. 2차원 데이터에 대한 CNN 알고리즘 구조

첫 번째는 입력 데이터값 $I(m,n)$ 가 가중합수를 가지고 있는 커널(kernel)이 일정한 흐름으로 순회하고, 다수의 합성곱을 병렬로 연산한다. 두 번째는 병렬로 연산한 값이 활성화 함수를 거치게 되며 입력 데이터에 대한 특징을 검출하여 피쳐맵(feature map)으로 출력한다. 세 번째는 풀링(pooling) 계층에서 풀링 함수를 사용해서 피쳐맵에 검출된 특징 데이터를 줄여 주는 작업을 진행한다. CNN 알고리즘은 합성곱 계층과 풀링 계층의 반복을 통하여 데이터의 특성을 추출한다. 마지막으로 합성곱 계층과 풀링 계층으로 추출한 데이터 세트를 완전 연결 계층을 통해서 $n \times m$ 행렬로 구성된 데이터를 $1 \times n$ 열벡터 배열로 데이터구조를 변형하여 데이터의 특징을 분류한다.^[17]




그림 2-11. 1차원 데이터에 대한 CNN 알고리즘 구조

위 그림은 1차원 CNN 알고리즘의 구조도이다. 1차원 CNN 알고리즘도 2차원 알고리즘의 학습과 같이 합성곱 계층과 풀링 계층으로 학습이 진행된다.

일반 신경망은 입력 신호와 뉴런이 전부 다음 계층에 완전하게 연결되는 구조이다. 동일 계층에 존재하는 뉴런은 어떤 연결도 공유하지 않는다. 크기가 큰 이미지에 일반 신경망을 사용할 때 거대한 수의 뉴런으로 인해 크기가 너무 커져서 과적합이 발생한다. 거대한 수의 뉴런들이 필요하므로 모델 크기가 커지게 된다. 이미지는 높이, 너비, 깊이(RGB)로 구성된 3차원 형상으로 간주하기 때문에 CNN의 뉴런은 3차원 형상을 이용하기 위해 3차원 데이터 형식으로 저장된다. 이미지 인식 등에 자주 사용되는 신경망의 구조로서 CNN을 대표로 손꼽지만, 자연 언어 처리(NLP) 등 다른 용도에서도 사용되고 있다.

CNN은 하나의 뉴런(neuron)을 여러 번 복사해서 사용하는 신경망(Neural Network)이라고 말 할 수 있다. 그렇게 함으로써 CNN은 뉴런의 형태를 보여주고 실제 학습이 필요한 파라미터의 개수를 매우 작게 유지하면서도 매우 많은 뉴런을 가지고 방대한 계산을 해야 하는 모델을 표현할 수 있다. 수학이나 컴퓨터에서 함수를 사용하는 것과 비슷하게 같은 뉴런을 여러 번 복사해서 사용하는 방식이라 할수 있다. CNN도 한번 습득한 뉴런은 여러 군데에 다시 사용할 수 있기 때문에 모델을 학습하기가 쉬워지며, 오차도 줄일 수 있다.

4. Region-based CNN

CNN은 합성곱 연산을 통해 픽셀 주변의 지역 정보를 표현하는 장점이 있지만, 다수의 객체 인식 및 객체의 위치 검출에는 한계점을 갖는다. R-CNN은 딥러닝 회귀(Regression) 방법을 적용하여 이러한 문제를 해결하였다.[18] R-CNN은 후보 영역(Region Proposal)을 생성하고 이를 기반으로 CNN을 학습시켜 이미지 내 위치한 객체를 검출하며, 3개의 모듈로 구성된다. 첫 번째 모듈은 입력 이미지에서 카테고리 독립적인 후보 영역을 생성하며, 검출기에 이용할 수 있는 후보 검출 영역을 탐지한다. CNN을 구성하는 두 번째 모듈은 모든 후보 영역으로부터 동일 크기의 특징 벡터를 추출하고, 세 번째 모듈에서는 클래스 고유의 선형 SVM을 이용하여 후보 영역 내의 객체를 분류한다.[19]

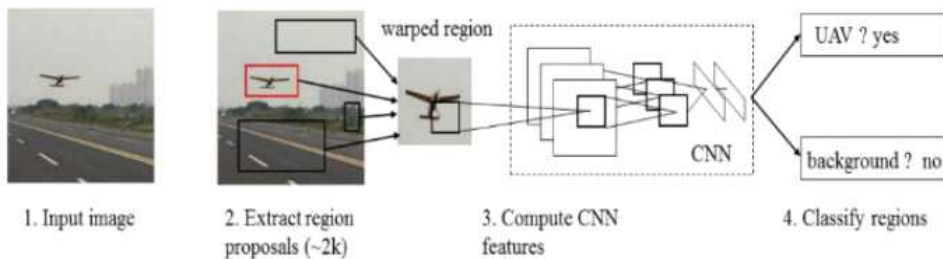


그림 2-12. Region-Convolutional Neural Network(R-CNN) System Overview

5. Fast R-CNN

Fast R-CNN은 후보 영역 생성 모듈이 CNN과 독립적으로 별도의 모듈에서 수행되기 때문에 학습 및 실행 속도에서 비효율적인 문제가 있다. 이를 보완하는 Fast R-CNN은 동일 합성곱 네트워크에서 객체 감지 및 후보 영역 생성을 수행한다. 후보 영역 생성에 대한 방법으로, 선택적 탐색(Selective Search) 기법 대

신에, 별도의 영역 제안 네트워크(RPN, Region Proposal Network)를 적용하여 추출된 기능 맵을 후보 영역으로 추정하여 객체를 인식한다.[20] 이전의 모든 CNN 모델과 비교하여, 기능 맵 추출 과정과 후보 영역 생성을 일련의 네트워크에서 수행하며, 기능 맵의 해상도가 입력 이미지의 해상도보다 낮으므로 계산량이 많이 감소하는 장점이 있다.

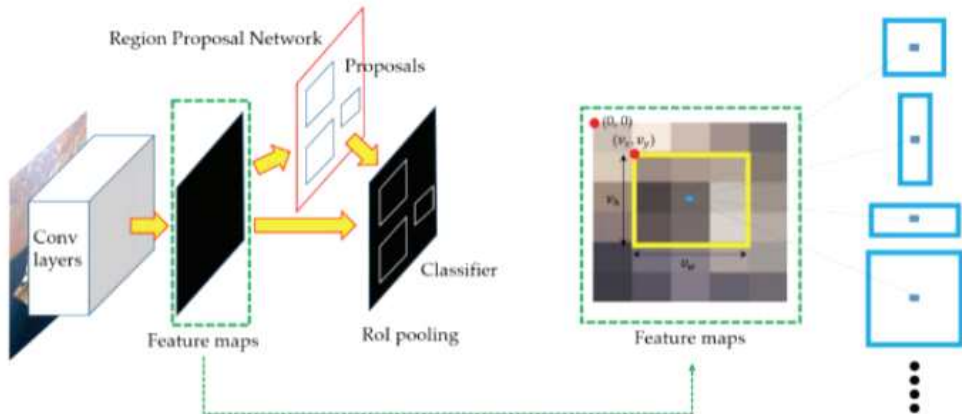


그림 2-13. Structures of Fast R-CNN and RPN

R-CNN과 비교하여 Fast R-CNN이 후보 영역을 생성하는 것과 생성하지 않는 것의 속도 차이가 확연히 나타난다. 이는 Fast R-CNN에서 후보 영역 생성이 성능상에서 크게 영향을 미친다는 것을 의미한다. Fast R-CNN은 선택적 검색에서 실행 시간을 감소하고 후보 영역을 추출하는 RPN을 설계하여 검출의 가속화를 얻는 방식으로 본 연구에서는 Fast R-CNN을 적용한다.[21]

6. YOLO v3

객체 검출에 대한 다른 접근법으로 YOLO(You Only Look Once)가 있다[22]. 이미지 내에 존재하는 객체와 해당 객체의 위치는 이미지를 한 번만 보고 예측할 수 있는 알고리즘이다. 이는 분류 대상의 객체로 감지하는 대신에 경계 상자

를 다차원적으로 분리하고 클래스 확률(Class Probability)을 적용하여 하나의 회귀 문제로 접근한다. 입력 이미지는 CNN을 통해 텐서(Tensor)의 그리드 형태로 나누고, 각 구간에 따라 객체인 경계 상자와 클래스 확률을 생성하여 해당 구역의 객체를 인식한다. YOLO는 후보 영역을 추출하기 위한 별도의 네트워크를 적용하지 않기 때문에 Fast R-CNN보다 처리시간 측면에서 월등한 성능을 보인다.




그림 2-14. YOLO Detection System

YOLO v3는 로지스틱 회귀(Logistic Regression)를 적용하여 경계 상자의 객관성 점수(Objectness Score)를 예측한다. 이러한 매칭 전략을 통하여 각 경계 상자마다 객체가 있는지 없는지를 산출하는 객관성 점수를 산출하고 앵커 박스와 Ground Truth 박스의 IOU(Intersection Over Union)가 가장 높은 박스를 1로 매칭시킨다. 경계 상자가 사전에 정의된 특정 임계값만큼 겹치지 않으면 예측은 무시될 수 있다. 또한 경계 상자 예측, 클래스 예측, 특징 검출기 및 반복적 검출 방식을 개선하였으며, 특징 피라미드 네트워크(Feature Pyramid Network) 개념과 유사한 방식으로 3개의 서로 다른 스케일 박스를 예측하여 다양한 스케일에서 특징을 추출한다. 이를 통해 결합한 특징 맵을 처리하고 보다 큰 텐서를 예측하기 위해 추가적인 합성곱 계층이 포함되었다.[23]

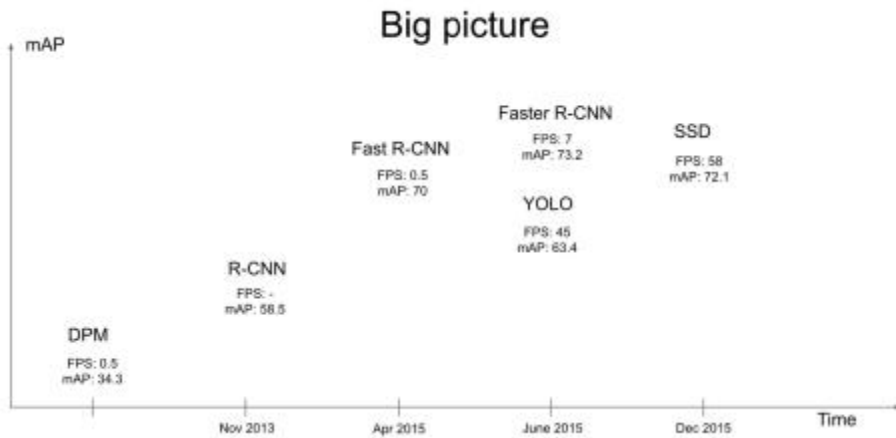


그림 2-15. 주요 객체탐지 모델의 성능과 연산시간 비교

YOLO는 Fast R-CNN에 비교해서 6배의 빠른 속도를 보여주고 있으며, YOLO의 특성이 빠르게 이미지를 탐지하는 것에 목표를 둔 모델이다. 기존의 다른 실시간 탐지 모델(Real-time detection mode)과 비교했을 때 거의 2배 정도 높은 mAP를 보여 줌으로써, 실시간으로 객체 탐지(object detection)가 필요한 비전 검사. 즉, 빠른 속도처리를 위한 외관검사 장비에 적합하다. 하지만, 아주 작은 결함나 결함이 상호 겹쳐져 있는 경우는 검출률이 떨어진다는 단점이 있다.[20]

Ⅲ. 시스템 설계

제 1 절 PCB 인공지능 검사 시스템 설계

1. 제안 시스템 구성도

AFVI 장비. 즉, “자동 외관검사” 장비는 설계된 도면(Gerber data)을 마스터링 작업하여, 실제 PCB 제품을 스캔한 카메라 영상과 비교 대조를 통해 양품과 불량을 판단하는 장비이다.

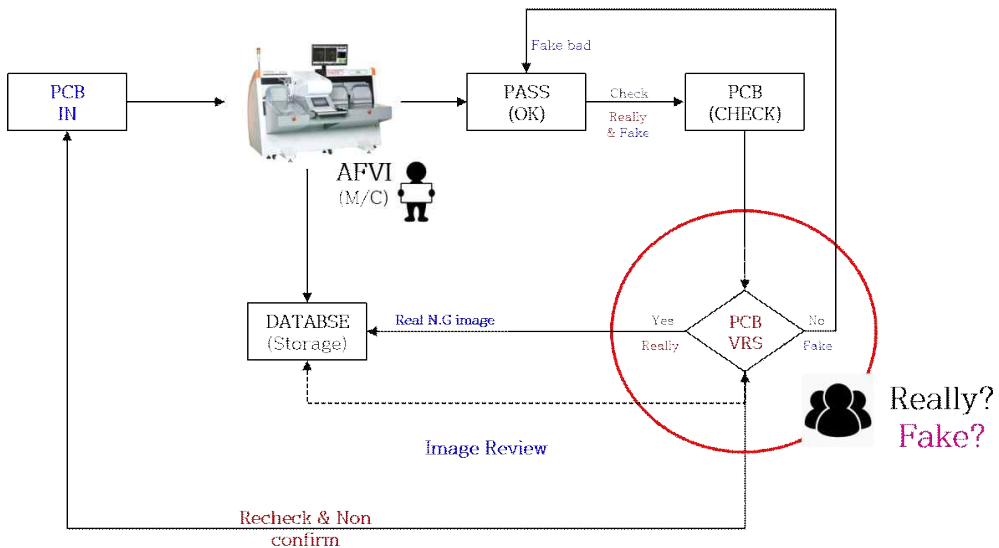


그림 3-1. AFVI(자동 외관검사) 장비의 작동원리

2. 제안 시스템의 작동순서

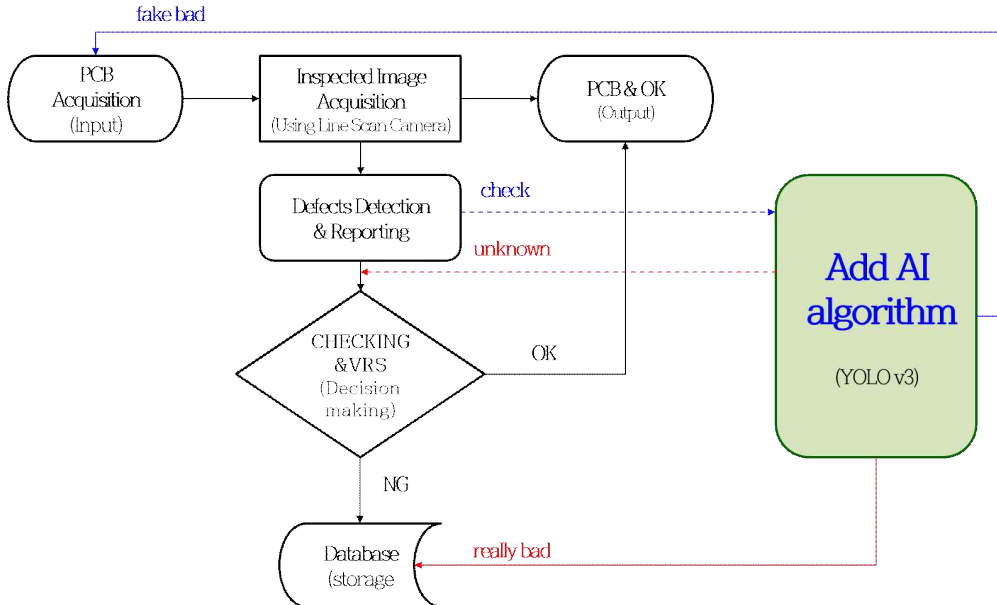


그림 3-2. 제안 시스템의 작동순서 흐름도

- 1) 검사할 PCB 기판을 왼쪽 로더 부분에 적재
- 2) AFVI 장비에서 자동으로 삽입되면서 판독된 PCB 제품을 배출
- 3) 배출된 PCB 기판은 ‘OK’ 혹은 ‘CHECK’로 구분
- 4) 이때 ‘CHECK’로 판독된 제품은 AI 알고리즘으로 판단
- 5) 판단된 PCB 기판은 진성과 가성으로 구분
- 6) 양품과 불량 판독이 애매한(알 수 없는) 제품은 사람이 직접 판단(VRS)
- 7) VRS를 통해서 재확인하고, 정확도가 떨어진 기판은 진성과 가성 구분
- 8) 가성 불량일 경우, ‘1)’ 순서부터 다시 진행 (반복 수행)
- 9) 진성 불량일 경우, ‘데이터베이스에 저장’하고 불량으로 처리

3. 제안 시스템의 결함 검사 대상

이미지 개수가 많은 PCB의 결함 형태와 결함의 종류가 다양한 것은 배제하고, 일정한 데이터 값을 얻기 위해서는 동일 유형의 이미지가 필요하다. 사전 프로그램 검토 시 Fast R-CNN과 YOLO V3의 정확도(precision)는 40% 이하였고, 재현율(recall)은 80% 이하였다. 초기 검사 대상을 선택하기에 앞서 PCB의 결함 종류가 많고 결함 크기가 작을뿐더러 색상도 비슷하여 정확한 판별이 어려웠다. 본 논문의 연구 배경을 고려하여 일정한 수준의 정확도는 보장하나, 제조시간을 단축하기 위해 속도가 빠른 YOLO V3를 선택하게 되었다.

먼저, 패드의 안쪽에 결함이 형성된 핀홀(pin hole)과 같이 패드 안쪽의 결함인 이물질(foreign particles)의 경우를 최적의 상태로 분류하여 효율성을 극대화하였으며, 라벨링 작업에 관한 시뮬레이션 알고리즘 최적화하였다. 아래의 [그림 3-3] (a) 핀홀과 (b) 이물질의 결함 사진이다.




그림 3-3. PCB 결함 예시 이미지

제 2 절 결함 검사 딥러닝 모델 설계

본 연구의 주목적은 PCB 기판의 결함 검사를 딥러닝 기반으로 분류하는 것이나, 국내에서는 이와 같은 기존 연구는 거의 드물어 결함을 분류하거나 패드 결함 혹은 PCB 회로 불량에 관하여 딥러닝을 적용한 연구에 대해 간략히 살펴보았다. PCB 기판 검사에서는 아주 작은 오류나 결함이 있어도 폭발과 같은 큰 피해를 볼 수 있으므로 정확도를 높이려고 하는 시도가 있었고, 이를 위해 정확도 면에서 매우 뛰어난 딥러닝을 활용하고자 하는 연구가 2010년 중반 이후 조금씩 등장하였다. 이때 대부분의 연구는 딥러닝 단일 모델로 문제를 해결하고 있는데 대다수 연구가 데이터양이 적고, 데이터 불균형 문제를 언급하지 않았다. 따라서 실제 생산 설비의 환경을 고려하지 못한 아쉬움이 있다.[24]

학습과 테스트 목적으로 데이터를 수집할 수 있도록 실제 검사장비를 도입한 회사와 협의를 하였으며, 분할된 결함 영상들을 공장의 일부 라인들에서 약 한 달간 결함 영상을 획득하였는데, 그 양은 모두 562,102장으로 엄청나게 많은 양을 수집할 수 있었다. 이는 PCB 기판의 제조 및 검사공정이 매우 빠르므로 단기간에 많은 양을 수집할 수 있었으나 검사과정에서 의미 없는 중복데이터가 많이 존재한다는 것을 의미한다. 하루에 AFVI 장비에서 검사되는 모델은 2개 혹은 4개 정도의 종류였으며, 동일 PCB 기판의 재검사로 인해 반복적으로 수집되는 것이 많았다. 하지만 결함의 종류와 유형이 많고, 특히 불특정한 패턴(불량유형)의 결함이 많은 것을 확인했다. 따라서 수집한 데이터로 딥러닝 모델을 학습하게 되면 데이터를 수집한 공장에서는 좋은 결과를 보이겠지만, 다른 유형의 PCB 기판을 생산하는 공장에서는 좋은 결과를 기대하기 힘들 수 있다.[25]

여러 공장에 적용할 수 있는 단일 모델을 학습하기 위해서는 매우 많은 PCB 기판의 데이터를 해당 생산 공장에서 장시간 오래 확보해야 하지만, 데이터를 수집할 때 발생하는 영상 저장 시간과 데이터양에 비해 생산량이 줄어들기 때문에 공장에서는 이러한 작업을 쉽게 허락해주지 않아서 데이터를 수집하는 것이 매우

힘들다. 또한 실제로는 공장에서 사용하는 PCB 기판의 영상은 외부에 공개하는 것을 꺼리므로 연구자들이 실험을 위해 데이터를 구하기가 힘들다.[26]

수집된 데이터의 실시간 객체 탐지 처리를 위해 단일 단계 방식으로 PCB 결함 이미지를 라벨링 하여 YOLO V3 알고리즘을 적용한 머신비전 AI로 결함의 위치를 인식하여 학습하고, CNN 모델 기반의 이미지 내 객체 판별 분류 자동화 즉, 진성/가성 불량률 찾아 학습 및 보정 예측 모델로써 검사자의 분류 값이 오류가 있으면 이를 보정, 학습 적용하여 예측값을 생성한다. 이는 정확한 PCB 결함 인식 및 판별 분류를 위해 딥러닝 학습용 PCB 결함 이미지 데이터를 수동으로 처리하고, 필요시에 따른 이미지 수집 및 DB 데이터에 저장하여 지속적인 학습을 통해 제안한 알고리즘 방법을 활용하여 최적화, 맞춤형 모델로 결함 분류의 지속적인 개선을 도모한다. [그림 3-4]와 [그림 3-5]는 제안한 알고리즘을 활용한 예시화면이다.

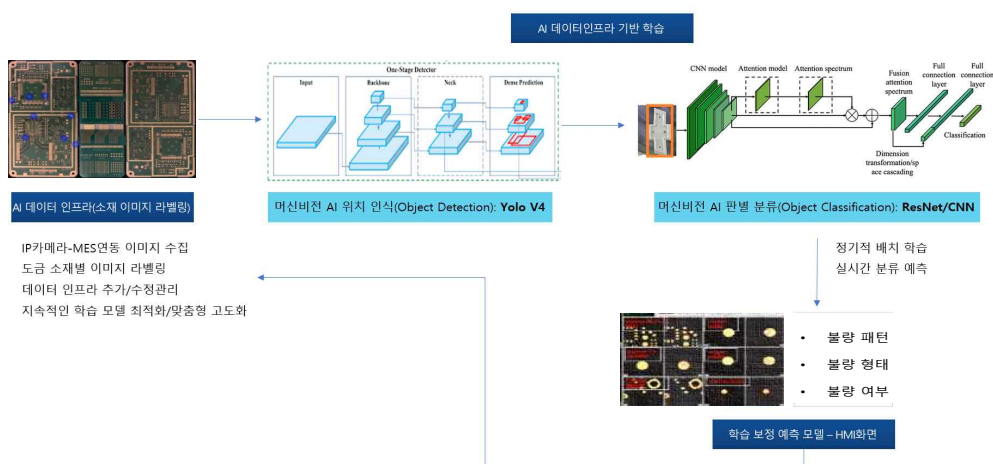


그림 3-4. 머신러닝 기법을 적용한 PCB 제안 AI 알고리즘

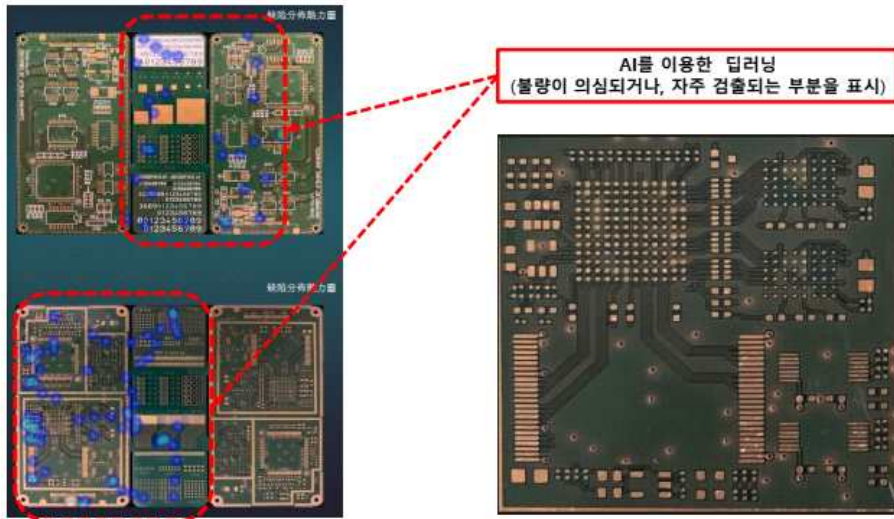


그림 3-5. 딥러닝 활용 시 예측 DATA

1. 학습 데이터 구성

본 연구에서 확보한 원본 이미지는 충분한 양의 데이터지만, 학습에 필요한 질적인 데이터라고 할 수 없으므로 단기간에 수집한 한정된 데이터셋을 활용하여 대표성을 가지는 데이터로 축소하고, 데이터 보강을 수행한 뒤 YOLO V3를 활용하여 데이터셋을 검증한다. PCB기판을 제작하는 특성을 충분히 고려하여 불특정 결함 군의 데이터셋에 대한 데이터를 보강하였다. 제한적인 환경에서 데이터를 수집하여 편향적인 데이터셋일 수도 있겠으나, 이렇게 제안한 방법을 활용한 딥러닝 모델의 학습으로 여러 PCB 환경에 적용할 수 있다. 여기에서는 PCB기판의 주요 결함 요소인 패드 안쪽의 불량요인을 중점적으로 수집하였다. [그림 3-6]은 수집한 데이터의 개수와 종류이다.

No	Class Name	Count
1	PD_foreign_particle	226
2	scratch	146
3	PT_foreign_particle	553
4	PT_slit	16
5	pin-hole	202
Total		1143

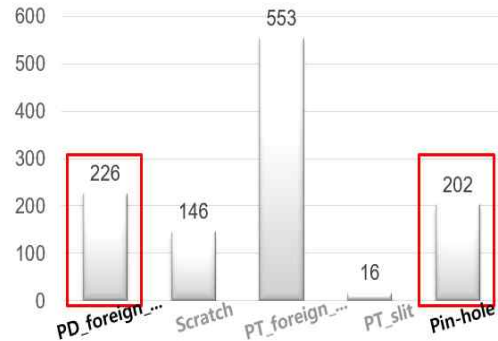


그림 3-6. 수집된 결함의 종류와 수

2. 데이터 수집 방법

공장에서 가동 중인 AFVI 장비의 결함 이미지들은 별도의 데이터베이스 공간에 저장된다. 데이터베이스는 이미지(jpg 파일)로 저장되며 PCB 기판의 전체 이미지를 잘라내어 결함 위치에 따라 일련의 번호로 저장한다. 이때 별도의 VRS(검사프로그램)로 작업하여 확인하거나 수동 저장이 가능하다. 제한적인 환경에서 데이터를 수집하기 때문에 데이터에 대한 별도의 보강 작업이 필요하다. 데이터 검증에 필요한 이물질(foreign particles), 스크래치(scratch), 슬릿(slit), 핀홀(pin hole)로 구분하여 이미지를 정제하였다.




그림 3-7. VRS에서 수집한 원본 이미지



그림 3-8. VRS 원본 이미지 전처리 과정

3. 데이터 라벨링

데이터 정제(전처리)가 끝나면 라벨링(OpenLabeling) 프로그램을 이용하여 라벨링 작업을 진행한다. 이때 라벨링 작업을 할 이미지들은 미리 옮겨 놓아야 한다. [그림 3-9]는 라벨링 도구를 사용한 예시화면이다.

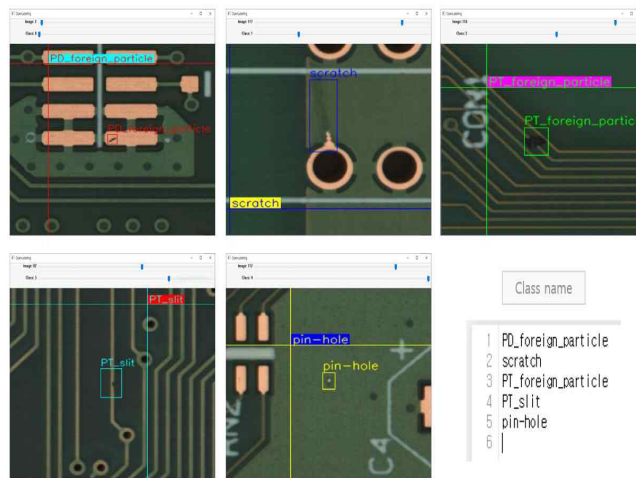


그림 3-9. 라벨링 도구를 사용한 예

4. 딥러닝 모델

4.1. 딥러닝 모델 구조

YOLO는 객체 탐지(object detection)의 중 하나로서 이미지 내의 개별 객체의 위치를 추적하고 분류하는 방법이다. 객체가 시야 안에 있을 때 바로 판단하는 사람의 시각 기관(human visual system)과 유사하도록 모델을 단일 신경망(single neural network)으로 구성하고, 객체 탐지를 단일 회귀 문제로 재구성하여 분석한다. 이미지에 대한 경계 상자(bounding box)로 영역을

설정하고, 영역 내 물체의 종류(class)나 유·무를 판단하여 분류 및 객체 탐지 문제를 한 번에 해결한다.

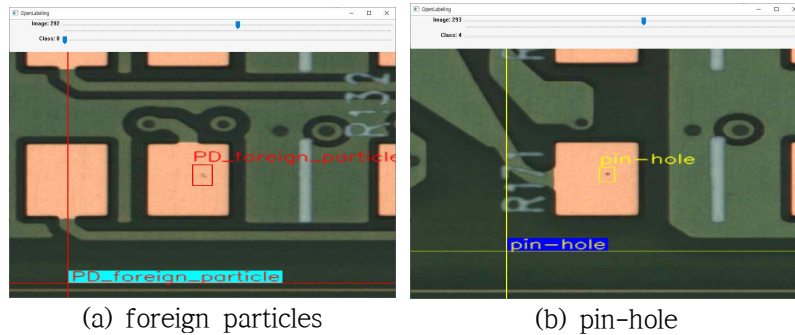


그림 3-10. YOLO V3 경계박스(bounding-box) 처리과정

4.2. 딥러닝 모델 학습 및 수정

[그림 3-11]은 학습 단계별(139회, 239회, 550회, 1,140회)로 이미지들을 학습하고, 패드의 이물질(foreign particles), 핀홀(pin hole)과 패턴의 이물질(foreign particles), 스크래치(scratch), 슬릿(slit)로 종류를 구분하여 Open Labeling-tool을 이용하여 라벨링 작업을 진행하였다. 1,140회 학습된 데이터를 YOLO V3를 통해 예측하였으나, 복잡한 데이터셋이 있을 때는 [그림 3-11]과 같이 탐지 성능이 좋지 않았다.

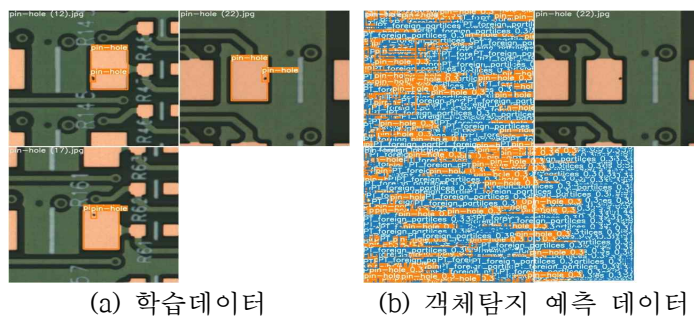


그림 3-11. YOLO V3 객체탐지 결과

이미지 학습 후 정확도가 20~40% 미만으로 나오는 경우도 발생하였다. 이것은 PCB 기판의 불량유형이 일정하지 않고, 아주 작고 복잡한 홀들과 가는 패턴의 영향으로 일정한 규칙이 있는 데이터를 얻기가 어려운 문제가 있기에 발생하는 것으로 예상된다. 효율적인 평가를 위해 특징이 명확한 결함 종류로 재분류하여 이를 검출하는 데 걸리는 시간으로 계산하였다. 검사 대상으로는 2개의 패턴, 패드 안쪽의 이물질(foreign particles)과 핀홀(pin hole)을 선택하였다. 데이터셋의 수가 많은 것보다 PCB의 결함 형상 즉, 모양이 다양한(변형이 많은) 것을 배제하고, 일정한 데이터를 얻기 위해서 같은 이미지를 선택하였다. 최적의 상태로 이미지를 재분류하여 객체를 탐지(object detection)한 결과 배경의 영상(인쇄의 영역(색상), 패턴(회로면), 패드)에 영향을 받은 것을 확인하였다.




그림 3-12. 재분류한 핀홀(pin hole) 결함 이미지

학습된 모델에서는 테스트 대상 이미지를 불러와 학습 및 평가를 수행해야 하므로 분리된 이미지에 대하여 결과를 따로 저장해야 한다. 이러한 결과는 텍스트 파일로 저장하며 좌표가 포함된 텍스트 파일을 각각의 데이터셋에 포함하여 학습 및 평가를 진행한다.

IV. 실험 및 평가

제 1 절 실험 데이터 구성 및 환경

1. 실험 데이터 구성

PCB 기판의 결함 이미지는 아주 작은 결함에도 품질의 신뢰성과 직결되는 문제가 되므로 고해상도를 가진다. GPU 학습의 빠른 처리를 위해서는 병렬처리가 필요하나, 제한된 메모리에서는 충분한 배치크기를 구성할 수 없다. 따라서 학습에 사용되는 이미지는 데이터베이스에 별도로 저장된 이미지들을 일정한 크기로 잘라내어 학습 및 테스트를 구성하였다.

2. 실험환경 구성

실험에서 사용한 하드웨어 및 소프트웨어의 환경은 [표 4-1, 4-2]와 같다.

표 4-1. 실험환경 하드웨어 구성

구분	테스트환경
CPU	i7-7700K @1.20Ghz이상
Memory	32.0GB(권장)
GPU	NVIDIA Geforce RTX 3090
Storage	SSD 1.0TB

표 4-2. 실험환경 소프트웨어 구성

구분	테스트환경
OS	Windows 10 pro
Image processing	Numpy 1.21.5. OpenCV-python 4.6.0.66
Deep Learning	Pytorch 1.13.0
Paralled processing	Nvidia CUDA 11.8
GUI	Pyside2 5.15.2, Matplotlib 3.5.2

3. 학습 및 검사 과정

실험에서 사용한 YOLO V3 학습 파라미터는 [표 4-3]과 같다.

표 4-3. 실험환경 YOLO V3 학습 파라미터

Parameter	Value
Learning rate	0.001
Momentum	0.9
Weight decay	0.0005
Activation function	Leaky Relu
Epochs	150
Batch Size	5

제 2 절 실험 결과 및 분석

본 연구에서는 Fast R-CNN과 YOLO를 비교 분석하였다. 이들은 합성곱 신경망(CNN, Convolution Neural Network)을 기반으로 성능 개선을 주도한 대표적인 알고리즘이다. 성능 개선의 모태는 같지만, 모델 구조에서 차이점을 있다. YOLO는 합성곱 신경망(CNN)을 처리하기 전에 이미지를 나눈다. Fast R-CNN은 전체 이미지를 유지하며 후보 영역을 나중에 나눈다.

1. 결합 객체 탐지 결과

1.1. 객체 탐지 모델의 성능을 시각적으로 확인한 결과

1,140개의 학습된 데이터를 YOLO 알고리즘을 통해 예측하였으나, 복잡한 데이터셋이 있을 때는 [그림 4-1]과 같이 성능 면에서 좋지 않았다. 그래프는 1,140개의 YOLO 알고리즘을 통해 시각적으로 결함을 확인할 수 있었다. 학습의 데이터셋 수가 많다고 하여 평가 결과값이 좋은 것만은 아니었다. 그림 4-1은 139개, 239개, 550, 1,140개에 대한 단계별 결과 그래프이다. 이미지 학습후 정확도가 20~40% 미만으로 나오는 때도 있다.

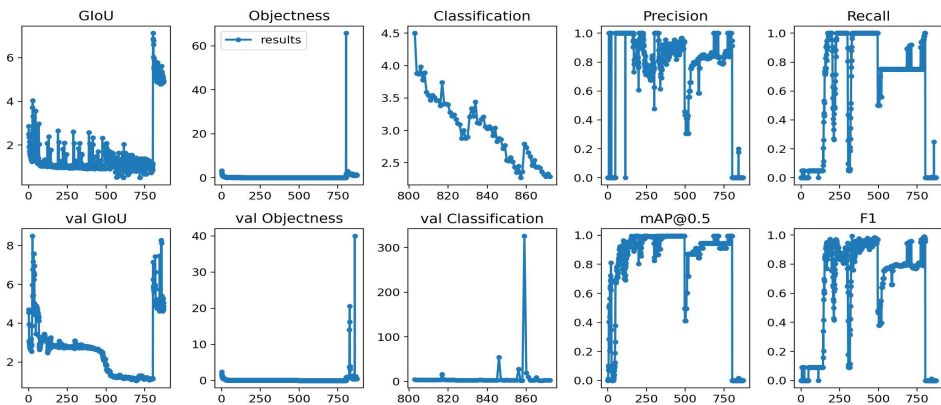


그림 4-1. 객체 탐지 모델의 성능을 시각적으로 확인한 결과

모델 성능평가 결과를 시각화한 결과 그래프와 같이 일반적으로 이미지의 개수가 많아지면 탐지 성능이 향상되지만 공정 과정에서 데이터를 얻기 위한 시간이 길어지며 효율성이 저하된다. 최적의 이미지 개수를 찾기 위해 재분류하여 효율성 극대화하는 실험을 진행하였다. 그리고 라벨링 작업에 관한 시뮬레이션 알고리즘 최적화하기 위해 모델을 5개로 학습하였다. 각 모델의 성능지표는 [그림 4-2]와 같다.

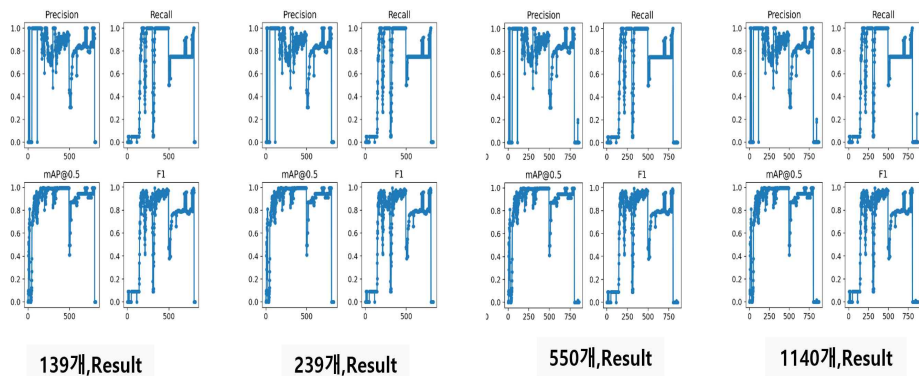


그림 4-2. 단계별 객체 탐지 모델의 성능을 시각적으로 확인한 결과

에폭(epoch)이 진행됨에 따라 4가지 성능지표 모두 1과 가까워지는 것을 확인할 수 있다. 하지만, 300개 이상의 이미지를 학습할수록 정확도와 재현율이 급격히 떨어지는 것을 볼 수가 있었다. 충분한 학습을 하기 위해 이미지 개수가 줄어들수록 더 많은 에폭을 진행하였고 4가지 지표가 0.9 이상으로 도달하는 시점에 학습을 중단하였다. 학습을 모두 끝낸 후, 학습되지 않은 테스트 데이터셋 50개를 준비하여 각각의 mAP@50, F1 score를 비교하는 실험을 진행하였다. 다음은 mAP@50 결과이다. mAP@50은 대표적인 객체 탐지(object detection) 성능지표로 detection의 정확도를 나타낸다. 이것은 PCB의 결함 유형이 일정하지 않고, 복합적인 홀과 패턴의 영향으로 일정한 데이터를 얻기가 어려웠다고 보인다. 본 논문에서 연구하고자 하는 바와 같

이 효과적인 성능을 찾기 위해서 재분류하여 탐지(detection) 소요 시간 시간을 측정하였다. [그림 4-3]은 재분류한 예측 검증 결과를 나타낸다.

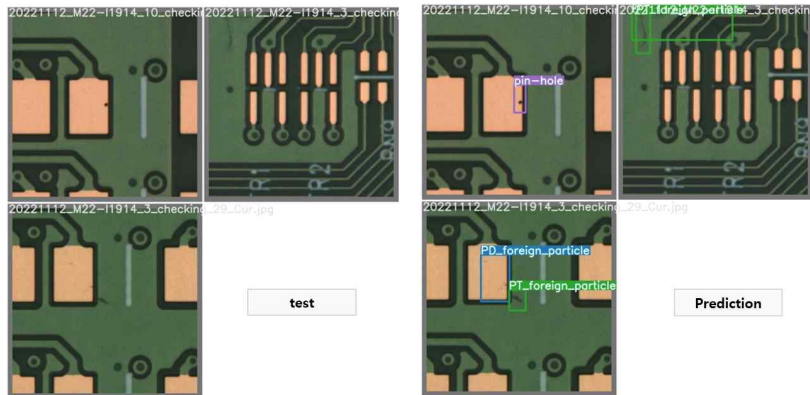


그림 4-3. 재분류한 예측 및 검증 결과

2. YOLO V3 수행 결과

육안식별이 가능하고, 구별이 쉬운 이미지인 ‘핀홀(pin-hole)’을 선택한 결과 정확도(precision)가 85% 이상, 재현율(recall)이 90% 이상 향상되었다. 재분류(이물질, 핀홀)한 이미지들을 객체 탐지한 결과 속도가 빠르게 진행되었으며, 예측(prediction) 결과도 정확하게 탐지되었다. mAP@0.5와 F1-score도 90% 이상 성능이 향상되었다.

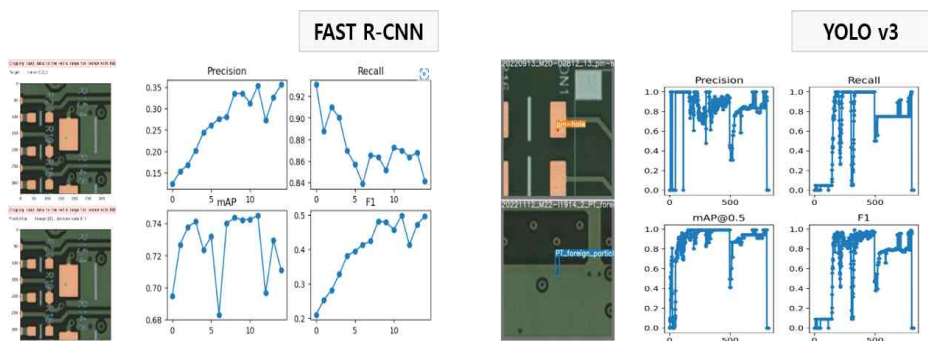


그림 4-4. FAST R-CNN과 YOLO V3의 검출 결과 비교

이미지 검출 속도를 비교한 결과 YOLO V3는 평균: 0.67s, FAST R-CNN은 평균: 31.7s로 YOLO V3가 약 46.8배 빠르게 검출되었다.

표 4-4. FAST R-CNN과 YOLO V3의 속도 비교

FAST R-CNN				YOLO v3			
1	33.961	11	31.555	1	0.664	11	0.672
2	31.433	12	31.732	2	0.652	12	0.679
3	31.56	13	31.528	3	0.691	13	0.682
4	31.547	14	31.525	4	0.687	14	0.669
5	31.538	15	31.554	5	0.704	15	0.685
6	31.480	6	0.689
7	31.567	7	0.642
8	31.575	8	0.693
9	31.450	9	0.667
10	31.495	10	0.683
Avg.(A)		31.700		Avg.(Y)		0.677	

다만, 300회의 학습 반복을 초과하면 과적합이 발생하므로 두 패턴의 데이터를 더 생성하거나 다른 패턴의 데이터를 추가하여 학습해야 한다. 이는 YOLO의 경계박스(bounding-box)의 작은 결함 패턴(결함+배경)의 경우를 위해 현재 PCB 크기 비율에 맞는 파라미터 조정으로 보강 작업이 필요하다.

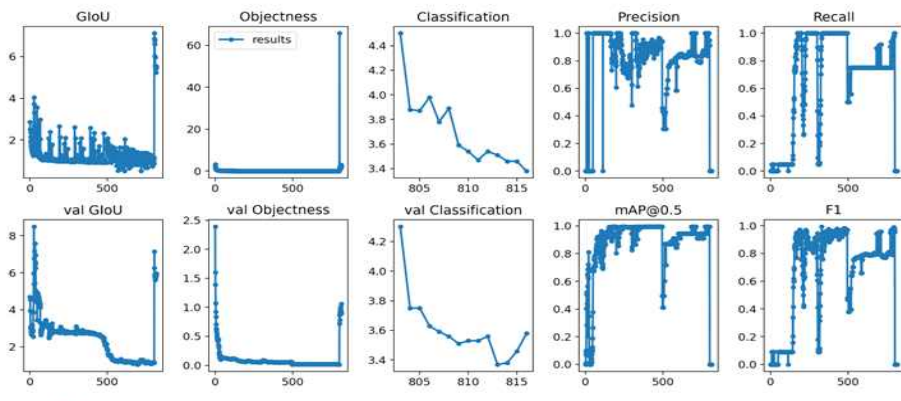


그림 4-5. 객체탐지 과적합 발생 결과

[그림 4-6]은 재분류한 탐지 결과를 시각적으로 나타냈다. 이 경우 정확도와 재현율이 모두 성능이 향상되었다.

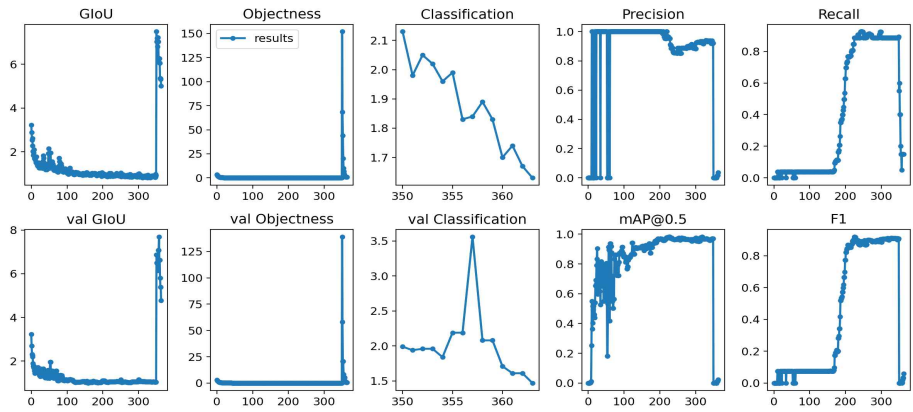


그림 4-6. 보강된 객체의 탐지 결과

V. 결론 및 향후 과제

본 연구에서 제안한 YOLO 알고리즘은 통해 결함 이미지를 빠르게 진성과 가성의 불량을 찾는 연구를 진행하였고, 두 종류(class)를 분류하여 학습하였다. 유사한 알고리즘은 많이 연구되고 있으나, 실제 PCB 산업현장에서 꼭 필요하며 품질의 지표를 체계화하기 위해 여러 가지 정보를 유기적으로 결합하여 저장하고, 데이터베이스의 소스를 수집하여 분석하면 충분히 가능할 것으로 보인다. 마스터 이미지(Gerber Data)를 최적화하여 일정한 작업 결과값이 나올 수 있도록 업무 프로세스 구축하면, 산업적인 측면에서 여러 공장에서 사용하는 데이터를 수집하는 시간을 단축시킬 수 있다.

이 연구에서는 대량의 데이터셋을 단 시간에 수집하였기 때문에 이미 객체 탐지(object detection)를 속도측면에서 비교 분석할 수 있었고, 향후에 다른 연구에서 참고할 만한 결함 분류방법의 일부를 제안하였다. 다양한 데이터셋을 조합하면 산업현장에서 사용할 수 있는 PCB에 특화된 검출 알고리즘에 대해 논할 수 있다. 하지만, 여러 조합된 데이터셋들을 검증할 방법이 없었으므로, 딥러닝을 활용하여 효율성있게 검증하고자 하였다. 이 연구를 통해 데이터셋을 검증할 때는 데이터셋의 아주 작거나, 결함의 이미지들이 겹치거나하여 정확도가 낮은 이미지들을 활용하는 것은 비효율적이라는 것을 확인할 수 있었으며, 이때 선정된 결함 이미지의 보강방법에 따라서 정확도의 차이를 확인할 수 있었다. 제안한 알고리즘의 방법대로 YOLO를 선정할 시 다른 조합의 데이터셋보다 좋은 제조시간 단축을 기대할 수 있다.

향후 결함의 종류(class)를 더 추가하고, 가장 효과적인 학습을 가능하게 하는 데이터베이스 확보를 고민해야 하며, 진성과 가성 데이터를 분류할 수 있는 GAN(Generative Adversarial Network)과 같은 딥러닝 모델도 비교하여 PCB만의 전용 검사 알고리즘 연구를 확장하고자 한다.

참고 문헌

- [1] BAUERNHANSL, Thomas, et al. Industrie 4.0-whitepaper fue-themen. Berlin: Bundesministerium für Wirtschaft und Energie-Plattform Industrie, 2014, 4: 11.
- [2] BITKOM/VDMA/ZVEI, Implementation Strategie Industrie 4.0, 2016
- [3] S. T. Barnard, “Automatic Visual Inspection of Printed Circuit Boards,” Advanced Systems for Manufacturing: Conference on Production Research and Technology, pp. 423-429, 1986.
- [4] MUN, Sun-Hwan. Automatic Optical Inspection of PCB PADs for AFVI. In: Proceedings of the Optical Society of Korea Conference. Optical Society of Korea, 2006. p. 469-471.
- [5] J. Song and T. Park, “Segmentation of Feature Extraction Regions for PCB Solder Joint Defect Classification,” Information and Control Symposium, pp. 13-14, 2017.
- [6] Y. Li, P. Kuo, and J. Guo. “Automatic Industry PCB Board DIP Process Defect Detection with Deep Ensemble Method,” 2020 IEEE 29th International Symposium on Industrial Electronics (ISIE). pp. 453-459, 2020.
- [7] Asifullah Khan, Anabia Sohail, Umme Zahoora, Aqsa Saeed Qureshi, “A Survey of the Recent Architectures of Deep Convolutional Neural Networks” , Computer Vision and Pattern Recognition.
- [8] Licheng Jiao, Fan Zhang, Fang Liu, Shuyuan Yang, Lingling Li, Zhizi Feng, Rong Qu, “A Survey of Deep Learning-based Object Detection” , IEEE Access, vol.7, pp.128837-128868, , 2019.
- [9] David G. Lowe, “Distinctive Image Features fromScale-Invariant Keypoints” , International Journal of Computer Vision, vol.60, pp.91-110, 2004.
- [10] Herbert Bay, Andreas Ess, Tinne Tuytelaars, Luc Van Gool, “Speeded-Up Robust Features (SURF)” , Computer Vision and Image Understanding, vol.110, issue.3, pp.346-359, 2008.

- [11] N. Dalal, B. Triggs, “Histograms of Oriented Gradients for Human Detection” , IEEE Conference on Computer Vision and Pattern Recognition, pp.886-893, 2005.
- [12] YongHwan Lee, Youngseop Kim, “Implementation of Object Feature Extraction within Image for Object Tracking” , Journal of the Semiconductor and Display Technology, vol.17, no.3, 2018.
- [13] Pedro F. Felzenszwalb, Ross B. Girshick, David McAllester, Deva Ramanan, “Object Detection with Discriminatively Trained Part-based Models” , IEEE Transactions on Pattern Analysis and Machine Intelligence, vol.32, issue.9, 2010.
- [14] Azeddine Elhasouny, Florentin Smarandache, “Trends in deep convolutional neural networks architectures: a review” , International Conference of Computer Science and Renewable Energies, pp.1-8, 2019.
- [15] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks” , Communications of the ACM, vol.60, no.6, 2017.
- [16] Ho Cheul Jung, Young Ghyu Sun, Donggu Lee, Soo Hyun Kim, Yu Min Hwang, Issac Sim, Sang Keun Oh, Seung-Ho Song, Jin Young Kim. (2019). Prediction for Energy Demand Using 1D-CNN and Bidirectional LSTM in Internet of Energy. Journal of IKEEE, 23(1), 134-142.
- [17] Ho Cheul Jung, Young Ghyu Sun, Donggu Lee, Soo Hyun Kim, Yu Min Hwang, Issac Sim, Sang Keun Oh, Seung-Ho Song, Jin Young Kim. (2019). Prediction for Energy Demand Using 1D-CNN and Bidirectional LSTM in Internet of Energy. Journal of IKEEE, 23(1), 134-142.
- [18] Ross Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik, “Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation” , IEEE Conference on Computer Vision and Pattern Recognition, pp.580-587, 2013.
- [19] Yurong Yang, Huajun Gong, Xinhua Wang, Peng Sun, “Aerial Target Tracking Algorithm Based on Faster RCNN Combined with Frame Differencing” , Aerospace, vol.4, no.32, 2017.
- [20] Kwanghyun Kim, Sungjun Hong, Baehoon Choi and Euntai Kim, “Probabilistic Ship Detection and Classification using Deep Learning” ,

Applied Sciences, vol.8, no.6, 2018.

[21] YongHwan Lee and Youngseop Kim, “Comparison of CNN and YOLO for Object Detection” Journal of the Semiconductor & Display Technology, Vol. 19, No. 1. , pp85-92, 2020.

[22] Joseph Redmon, Santosh Divvala, Ross Girshick, AliFarhadi, “You Only Look Once: Unified, Real-time Object Detection” , IEEE Conference on Computer Vision and Pattern Recognition, pp.779-788, 2015.

[23] Joseph Redmon, Ali Farhadi, “YOLO v3: An Incremental Improvement” , Computer Vision and Pattern Recognition, 2018.

[24] S. M. Gang & J. J. Lee, “Coreset Construction for Character Recognition of PCB Components Based on Deep Learning,” Journal of Korea Multimedia Society Vol. 24, No. 3, pp.382-395, March 2021.

[25] S. Lee and J. Lee, “In-Line 3-D Inspection for PCB Solder Paste,” The Fall Conference on Korea Multimedia Society, pp. 492-495, Nov. 2004.

[26] S. Gang, N. Fabrice, and J. Lee, “Coresets for PCB Character Recognition based on Deep Learning,” 2020 International Conference on Artificial Intelligence in Information and Communication (ICAI IC), Fukuoka, Japan, 2020, pp. 637-642, 2020.

ABSTRACT

A study on the printed circuit board inspection method using artificial intelligence

by Ji-Hoon Kim

Advisor : Prof. Yoo-Seok Bae, Ph.D.

Department of Computer Engineering

General Graduate School

Tech University of Korea

Recently, the final appearance inspection equipment (AFVI, Auto Final Visual Inspection) used in the industry has been introduced and installed to strengthen quality control and is in operation, but its performance is not fully used, and systematic accumulation and analysis of data is insufficient. In addition, it takes a lot of time to analyze the images of the extracted video, such as rechecking through another program (VRS), and it is practically impossible to find a completely flawless product when checking with the eyes.

In this study, YOLO V3, an artificial intelligence algorithm suitable for reducing repetitive inspections in the final inspection process of printed circuit boards (PCBs, Printed Circuit Boards, hereinafter PCBs) using artificial intelligence, and considering the characteristics of defects labeled according to defective images was used. This is because the model is composed of a single neural network similar to the human visual system that immediately judges an object when it is in the field of view, so the images determined while performing supervised learning are more reliable. It will be the inspection method and will also be an important indicator for the inspector's decision-making.

The 'product that the user (customer) wants' analyzed using artificial intelligence (a product that has been negotiated or specified in the standard specification), that is, a selected product, reduces manufacturing time by reducing the repetitive work

of inspectors working on final inspection equipment. It can be shortened and competitive in terms of delivery time. Defective images of frequently detected products among the learned data are stored, and object search is performed on the defective images, thereby reducing the cost of rework defects and improving the quality level through intensive quality issues.

감사의 글

석사과정을 통해 이루고자 하는 학업의 꿈을 적극적으로 지원해주신 단현국 대표님께 감사드립니다. 바쁘신 와중에도 부족한 저에게 논문을 지도해주신 배유석 교수님께 감사드립니다. 심사에 도움을 주신 최종필 교수님, 정두희 교수님께도 감사드립니다.

2년이란 시간은 저에게 많은 생각을 하게 한 시간이었습니다. 학업과 같이 회사에서 또한 힘들고, 지친 시간들을 배움으로부터 잘 이겨 나갈 수 있게 격려와 지원을 아끼지 않았던, 우리 아내 김진향님과 토끼 같은 우리 딸들 예빈, 예린 에게도 부족한 아빠역할을 이해해 줘서 고맙다고 말을 전하고 싶습니다.

누구보다 기뻐해주신, 우리 부모님께 감사드립니다. 아울러, 석사과정에 함께 있어 지원을 아끼지 않았던, 로드피아 이상덕 대표님께도 깊이 감사드립니다.

코로나로 인해 지치고 힘든 일들이 많았던, 한해 두해를 거치며 앞으로 무엇을 해야 할 지 고민도 많았기에 막막했던 미래도 최선을 다하는 삶이 될 수 있도록 노력하겠습니다.

행복한 삶이 무엇인지 무엇을 위해 행복한지를 깨닫게 한 좋은 시간이었기에 항상 최선을 다하며, 힘들었던 지난 일들을 발판 삼아 더욱더 열심히 살겠습니다. 부족했던 학문의 꿈이 조금이나마 더 정진할 수 있도록 노력하겠습니다.

일일이 다 설명할 수 없지만, 석사과정을 잘 마무리할 수 있도록 도와준 학우 분들에게도 감사드립니다.