



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.


다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

碩士學位 請求論文

指導教授 李 知 炯

심층 회선 신경망을 이용한 SMT 제조 공정의 가성 불량 검출 방법

成均館大學校 一般大學院

DMC 工學科

金 政 旭

碩士學位 請求論文

指導教授 李 知 炯

심층 회선 신경망을 이용한 SMT 제조 공정의 가성 불량 검출 방법

Deep Convolutional Neural Networks for Detection of
False Defects in SMT Manufacturing Process

成均館大學校 一般大學院

DMC 工學科

金 政 旭

碩士學位 請求論文

指導教授 李 知 炯

심층 회선 신경망을 이용한 SMT 제조 공정의 가성 불량 검출 방법

Deep Convolutional Neural Networks for Detection of
False Defects in SMT Manufacturing Process

이 論文을 工學 碩士學位請求論文으로 提出합니다.

2018 年 4 月 日

成均館大學校 一般大學院

DMC 工學科

金 政 旭

이 論文을 金 政 旭의 工學
碩士學位 論文으로 認定함.

2018 年 6 月 日

審査委員長

審査委員

審査委員

목차

목차	i
표 목차	iii
그림 목차	iv
논문 요약	v
제1장 서론	1
제2장 이론적 배경 및 관련 연구	4
2-1. 배경 지식	4
A. 영상 회선 (Image Convolution)	4
B. 부차 추출 (Subsampling)	6
C. SVM (Support Vector Machine)	6
D. 회선 신경망 (Convolutional Neural Network)	8
2-2. 관련 연구	9
A. AlexNet	10
B. ZFNet	11
C. GoogLeNet	12
D. 회선 신경망을 이용한 영상 인식에 관한 연구	13
제3장 연구 방법	15
3-1. 가성 불량 검출 모델 제안	15
3-2. 심층 회선 신경망 모델 선정	18
A. Residual Network	18
B. Inception V3	20

제4장 실험	23
4-1. 실험 데이터(Dataset) 분류	23
4-2. 모델 학습 및 평가	24
A. 평가 지표	24
B. DefectNet 학습 (이진 클래스 분류기)	25
C. ComponentNet 학습 (다중 클래스 분류기)	28
D. 제안 모델 실험	30
E. 결과 및 평가	33
제5장 결론	36
참고 문헌	38
Abstract	40

표목차

표 4-1. 부품A의 DefectNet 성능 비교	25
표 4-2. 부품B의 DefectNet 학습 및 테스트 데이터 세트 구성	26
표 4-3. 부품C의 DefectNet 학습 및 테스트 데이터 세트 구성	26
표 4-4. 부품B, 부품C의 DefectNet 모델 성능	27
표 4-5. ComponentNet에 사용된 데이터 세트 구성	28
표 4-6. 클래스 수에 따른 ComponentNet 성능 비교	30
표 4-7. 모델 분류 결과에 따른 구분	31
표 4-8. 기준 확률 변화에 따른 결과 비교	31
표 4-9. ComponentNet-20의 출력	32
표 4-10. DefectNet-8의 출력	32

그림목차

그림 1-1. SMT 생산 라인 구성도	1
그림 1-2. 주요 가성 불량 발생의 예	2
그림 2-1. 2차원 회선 연산	4
그림 2-2. 회선 연산의 필터 사이즈 변화에 따른 결과 비교	5
그림 2-3. 부차 추출	6
그림 2-4. SVM의 선형 경계선 학습 원리	7
그림 2-5. 일반적인 심층 회선 신경망 구조	8
그림 2-6. AlexNet의 구조	10
그림 2-7. ZFNet의 Deconvolution Layer(좌)와 Convolution Layer(우)	11
그림 2-8. GoogLeNet의 구조	12
그림 2-9. Inception 모듈	13
그림 3-1. AOI에서 수집되는 부품 영상 예시	16
그림 3-2. 제안 모델의 불량 판정 프로세스	17
그림 3-3. Residual Network의 구조	18
그림 3-4. ResNet에 적용된 Building Block	19
그림 3-5. 회선 연산의 인수분해	20
그림 3-6. Inception V3 모델에 적용된 Inception 모듈	21
그림 3-7. Inception V3 모델의 구조	22
그림 4-1. 부품 별 가성 불량 및 진성 불량 예시	23
그림 4-2. 부품A의 DefectNet 학습 그래프. ResNet-50(a), Inception V3(b)	25
그림 4-3. 부품B(a)와 부품C(b)의 DefectNet 학습 그래프	27
그림 4-4. ComponentNet의 학습 그래프 12-Class(a), 20-Class(b), 30-Class(c),	

60-Class(d)	29
그림 4-5. 일반적인 사물 인식에 사용되는 데이터 세트	33
그림 4-6. 가성 불량 인식 문제에 사용되는 데이터 세트	34

논문요약

심층 회선 신경망을 이용한 SMT 제조 공정의 가성 불량 검출 방법

제품을 생산하는 많은 생산 라인에서 비전(Vision) 검사기를 도입하여 불량 검출 자동화를 이루었지만 검사 설비의 규칙 기반(Rule-base) 알고리즘으로 인해 발생하는 가상 불량(False Defect)은 여전히 해결해야 할 문제이다.

기존의 검사 알고리즘과 달리 최근 활발히 연구되고 있는 딥러닝(Deep Learning) 방식의 심층 회선 신경망(Deep Convolutional Neural Network)들은 영상 인식 분야에서 월등한 성능을 보여주고 있고 제조 현장 또한 스마트 팩토리(Smart Factory) 구축을 위해 각종 센서 및 IoT(Internet of Things) 기술 적용이 확산되어 학습에 필요한 데이터 수집이 용이한 환경이 되었다. 이러한 환경을 바탕으로 실제 생산 라인에서 수집한 불량 영상 데이터와 심층 회선 신경망을 이용하여 가상 불량 문제를 해결할 수 있을 것으로 예상하였다.

본 논문에서는 심층 회선 신경망을 이용하여 PCB(Printed Circuit Board)에 표면 실장을 하는 SMT(Surface Mounting Technology) 제조 공정에서 활용 가능한 가상 불량 검출 모델에 관한 연구를 진행하였고 실제로 수집한 영상 데이터 학습을 통해 제안 모델의 가상 불량 검출 성능을 확인하였다.

주제어 : SMT 제조 공정, 가상 불량, 딥러닝, 회선 신경망, 스마트 팩토리

제1장 서론

컴퓨터 비전과 영상처리 기술은 현재 제품 대량생산을 위한 제조 공정의 많은 부분에서 활용되고 있다. 특히 제품의 품질 향상 및 가격 경쟁력 확보를 위한 공정 자동화 분야에 많은 어플리케이션들이 적용되고 있으며 그 중 제품의 공정 불량을 검출하는 AOI(Automated Optical Inspector)는 SMT(Surface Mounting Technology) 제조 공정의 필수적인 자동화 비전 검사 시스템이다.




그림 1-1. SMT 생산 라인 구성도

[그림 1-1]은 PCB(Printed Circuit Board)에 표면 실장을 하기 위한 SMT 생산 라인의 일반적인 구성을 나타내며 크게 3가지 공정으로 분류된다. 땀납(Solder Paste)을 인쇄하는 인쇄 공정(Screen Printer), 부품을 장착하는 장착 공정(Chip Placement), 가열하여 납땀을 수행하는 납땀 공정(Reflow)이 그것이며 각 공정 사이에 3대의 AOI가 배치되어 있다. 첫 번째 AOI는 땀납의 인쇄 상태를 검사하는 인쇄 검사기이고 두 번째는 부품의 장착 상태를 검사하는 장착 검사기, 그리고 마지막으로 납땀 상태를 검사하는 납땀 검사기가 있다. 이러한 AOI는 제품 생산 단계에서 불량을 검출하여 불량 제품의 유출을 방지하고 시장 불량으로 인해 발생할 수 있는 잠재적인 손실을 막아준다.

그러나 AOI는 전통적인 규칙 기반(Rule-base) 방식의 고정된 검사 알고리즘으로 동작하기 때문에 작은 오차에도 민감하게 반응하여 실제 불량인 양품을 불량으로 오판하는 가성 불량(False Defect) 문제를 갖고 있다.

규칙 기반 검사 알고리즘은 부품의 장착 위치, 틀어짐 허용 범위, 등록된 기준 영상과의 유사도 등을 설정하여 검사를 수행한다. 기준을 엄격하게 설정할 경우 가성 불량 발생 빈도가 늘어나게 되고 반대로 완화할 경우 진성 불량(True Defect)이 검출되지 못할 확률이 높아진다.



그림 1-2. 주요 가성 불량 발생의 예

[그림 1-2]의 예시와 같이 부품 영역 내에서의 틀어짐, 부품 외관 패턴의 편차, 주변의 높은 부품으로 인한 조도 부족, 이물 등과 같은 작은 오차로 인해 많은 가성 불량이 발생하고 있다. 실제로 AOI에서 불량으로 검출된 제품들 중 가성 불량이 차지하는 비율은 매우 높은 편이며, 이러한 가성 불량을 처리하기 위해 제조 라인에서는 별도의 육안 검사를 위한 인력을 운영해야 한다. 이는 결국 불량 발생에 대한 처리 시간과 비용을 증가시키게 된다.

이와 달리 딥러닝 방식은 실제 환경에서 취득한 데이터로부터 판단 기준을 학습하기 때문에 보다 유연한 기준 설정이 가능하고 기존 검사 시스템의 가성 불량 문제를 해결하는 좋은 방법이 될 수 있다.

이러한 딥러닝 방식의 검사 시스템을 실제 생산 라인에 적용하기 위해서는 다음 세 가지 조건을 만족해야 한다. 1) 높은 검사 정확도를 확보해야 하고 2) 입력 영상에 대한 처리 속도가 빨라야 하며 3) 학습에 소요되는 시간이 길지 않아야 한다. 최근 제조 현장에서는 지능화 된 스마트 팩토리(Smart Factory) 구축을 위해 각종 센서 및 IoT(Internet of Things) 기술 적용이 확산되어 데이터를 수집하기 용이한 환경이 되었다. 그리고 영상 인식 분야에 특화된 인공신경망인 심층 회선 신경망을 이용한 영상 내 사물 인식 관련 연구가 활발히 진행되고 있고 인식을 또한 높아지고 있다. 이러한 결과들을 바탕으로 SMT 검사 공정 도메인에서 취득한 영상 데이터와 적절한 구조의 심층 회선 신경망을 이용하여 우수한 성능의 가성 불량 판정 시스템을 구현할 수 있을 것으로 예상된다.

본 논문에서는 실제 SMT 제조 공정의 AOI 영상 데이터와 심층 회선 신경망을 이용하여 가성 불량을 검출하는 방법을 제안하고 높은 검사 정확도 및 학습 속도 향상을 위해 잘 알려진 심층 회선 신경망들의 성능을 비교한다.

제2장 이론적 배경 및 관련 연구

2-1. 배경 지식

A. 영상 회선 (Image Convolution)




그림 2-1. 2차원 회선 연산

컴퓨터에서 영상 데이터는 2차원 배열의 숫자 데이터 집합으로 표현되며 흑백 영상의 경우 단일 채널, 컬러 영상의 경우 RGB의 3가지 채널을 갖는다. 많은 영상 인식 알고리즘에서는 영상의 어떠한 특징을 추출하기 위해 원본 영상에 대해 [그림 2-1]과 같이 작은 영역의 필터(Kernel)를 이용한 2차원 회선 연산을 사용한다. 회선은 원본 영상에 필터를 대응시켜 같은 위치의 픽셀값을 서로 곱한 뒤 그 결과를 모두 합하는 연산이다. 연산의 결과로 새로운 Feature Map이 생성되며

필터의 크기가 3×3인 경우 2차원 회선 연산은 수식은 다음과 같다.

$$Output(i,j) = \sum_{k=-1}^{+1} \sum_{l=-1}^{+1} Input(i-k,j-l) \times Filter(i-k,j-l) \quad (1)$$

필터를 이동시키며 대상 영상의 전체 영역에 대해 회선 연산을 수행하면 설정된 필터의 가중치(Weight)에 따라 영상이 필터링 된다. 따라서 회선 연산에서는 영상으로부터 추출하고자 하는 특징에 따라 가중치를 설정하는 것이 중요하며 필터의 사이즈와 한번에 이동하는 크기(Stride) 또한 고려해야 할 요소이다.




그림 2-2. 회선 연산의 필터 사이즈 변화에 따른 결과 비교

[그림 2-2]에서 나타낸 것과 같이 필터의 크기가 클수록 그리고 Stride가 클수록 이동할 수 있는 영역이 줄어들기 때문에 필터링 된 영상의 크기가 더 작아진다.

B. 부차 추출 (Subsampling)




그림 2-3. 부차 추출

부차 추출은 [그림 2-3]과 같이 어떠한 영역 내에서 대표 값을 추출하는 방법이다. 주로 최대값 추출과 평균값 추출이 많이 사용되며 대표 값 추출 후 영상의 크기가 줄어드는 다운사이징이 일어난다. 회선 신경망에서 부차 추출을 사용하는 경우 신경 세포가 가장 강한 신호를 전달하고 그보다 약한 신호를 무시하는 것과 유사하게 최대값 추출을 가장 많이 사용한다.

C. SVM (Support Vector Machine)

SVM은 최근까지 가장 보편적으로 사용되고 있는 데이터 분류를 위한 기계 학습 모델이다. 이름에서 말하는 바와 같이 학습 데이터가 벡터 공간에 위치한다고 가정한다. 벡터 공간은 학습 데이터가 위치한 다차원 공간이며 SVM은 벡터 공간에서 학습 데이터가 속한 두 개의 그룹을 구분하는 선형 분리자(Linear Classifier)를 찾는 모델이다.




그림 2-4. SVM의 선형 경계선 학습 원리

[그림 2-4]의 예시와 같이 SVM의 목표는 두 개의 그룹(□, ○)을 분리하는 경계선(Boundary)을 찾는 것이다. 이 경계선은 두 그룹을 구별하면서 Margin을 최대화 하며 다음과 같은 식으로 나타낼 수 있다.

$$w^T x + w_0 = 0 \quad (2)$$

Margin을 최대화 하는 이유는 경계선을 기준으로 두 그룹이 멀리 떨어질수록 더 높은 신뢰도로 그룹을 분리할 수 있기 때문이다. SVM의 이름에서 Support Vector란 이 경계선을 각 그룹의 방향으로 평행 이동 했을 때, 최초로 만나게 되는 데이터를 말한다. 각각의 학습 데이터가 어떤 그룹에 속하는지 라벨링(Labeling)이 되어 있기 때문에 지도 학습(Supervised Learning) 방식에 속하며 식 (2)에서 계수에 해당하는 벡터 w 의 값들을 학습하게 된다.

D. 회선 신경망 (Convolutional Neural Network)

회선 신경망은 다양한 필터와 회선 연산을 활용하여 영상으로부터 특징 정보를 효과적으로 추출하는 대표적인 인공신경망이다. 영상 내에 존재하는 특정 사물(Object)을 인식하기 위해서는 해당 사물이 다른 사물과 구별되는 특징을 알고 인식해야 하는데 영상 데이터 학습을 일반적인 다층 신경망으로 구현할 경우 사물의 위상(Topology)을 고려하지 않고 가공되지 않은 데이터에 대해 직접적인 처리를 해야 하므로 방대한 양의 데이터와 학습 시간을 필요로 하게 된다. 따라서 이 방법은 실제적인 적용에 어려움이 있다. 하지만 회선 신경망의 영상 데이터 처리 과정에는 특징 추출 단계와 위상 변화에 대한 영향을 최소화 하는 처리 단계가 포함되어 있기 때문에 보다 우수한 성능의 분류기 구현이 가능하다.

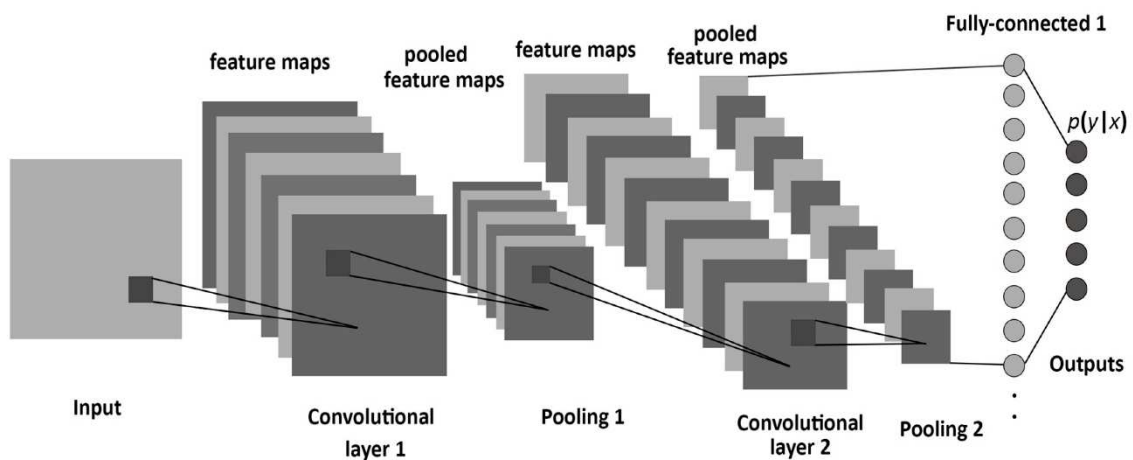


그림 2-5. 일반적인 심층 회선 신경망 구조

[그림 2-5]는 일반적인 심층 회선 신경망의 구조를 보여준다. 먼저 구조를 살펴보면 입력 영상에 대해 회선 연산을 수행하는 Convolution Layer와 부차

추출을 수행하는 Pooling Layer가 반복적으로 사용되어 영상의 특징 정보를 추출하고 신경망의 마지막 단계에는 SVM과 같은 완전 연결(Fully-connected)된 층의 분류기가 추출된 특징 정보를 바탕으로 해당 특징이 어떤 클래스를 나타내는지 학습한다.

보다 상세히 살펴보면 각 Convolution Layer에서는 다수의 필터를 사용하여 입력 데이터에 대해 회선 연산을 수행하고 출력으로 회선 연산의 수만큼의 Feature Map이 생성된다. Feature Map들은 각 필터의 가중치에 따라 서로 다른 특징이 추출된 결과물이다. 생성된 Feature Map들은 다시 Pooling Layer에서 최대값 추출 방식으로 부차 추출되면서 특징 중 강한 정보만 남고 약한 정보는 제거된다. 이러한 회선 연산과 부차 추출을 여러 번 반복하면 Feature Map의 크기는 줄어들면서 강한 신호만 남게 되므로 입력 영상으로부터 전체 영상을 대표할 수 있는 전역적(Global)인 특징을 추출 할 수 있으며 동시에 인식하고자 하는 대상의 위상 불변성(Invariance)을 확보할 수 있다. 이렇게 얻어진 특징을 마지막 단의 완전 연결된 신경망을 통해 학습시키면 2차원 영상으로부터 위상 변화에 강인한 인식 성능을 얻을 수 있게 된다.

전통적인 회선 연산을 이용한 영상의 필터링에서 필터의 가중치들은 추출하고자 하는 특징에 따라 고정되지만 회선 신경망에서는 입력된 영상 데이터 학습을 통해 최적의 필터 값들을 결정하게 되는 점이 다르다.

2-2. 관련 연구

컴퓨터를 이용하여 영상 안에 존재하는 사물(Object)들을 구별하고 인식하는 문제는 지속적으로 연구되어 왔다. 특히 2010년부터 매해 개최된 ImageNet이라는 대량의 영상 데이터베이스를 이용한 영상 인식 대회 ILSVRC(ImageNet Large Scale

Visual Recognition Challenge)에서 심층 회선 신경망이 뛰어난 인식 성능을 보이며 주목을 받게 되었고 해를 거듭하며 여러 구조의 회선 신경망들이 발표되었다. 이 절에서는 ILSVRC에서 우수한 성능을 보인 잘 알려진 몇 가지 심층 회선 신경망의 구조들과 이를 활용한 관련 연구들에 대해 소개한다.

A. AlexNet

Krizhevsky Alex 외 2인이 개발한 AlexNet[1]은 ILSVRC 2012에서 압도적인 사물 인식 성능을 보이며 영상 인식 분야에서 회선 신경망이 주목받는 계기가 되었다.




그림 2-6. AlexNet의 구조[1]

AlexNet은 [그림 4]와 같이 2개의 GPU를 사용하는 병렬 구조로 설계되었다. 총 5개의 회선 층(Convolution Layer)과 3개의 완전 연결 층(Fully-connected Layer)로 구성되어 있으며 약 65만개의 뉴런 및 6억 3000만개의 연결(Connection)을 가진 방대한 구조로 총 1000개의 객체를 분류 할 수 있다. 컬러 영상을 입력으로 받을 수 있으며 해상도는 $227 \times 227 \times 3$ 이다. 망(Network)의 크기가 매우 크기 때문에 학습 속도가 느린 문제가 있는데 이를 향상시키기 위해 활성화 함수로

ReLU(Rectified Linear Unit)을 사용하였고 학습 속도가 6배 가량 향상되었다.

B. ZFNet

AlexNet 등장 이후 Matthew D. Zeiler 외 1인은 회선 신경망이 어떤 원리로 동작하고 좋은 성능을 내는지 보다 잘 이해하기 위한 방법을 고안해낸다.[2] Deconvolution 이라는 방식의 시각화(Visualizing) 기법을 통해 AlexNet의 기본 구조를 개선할 수 있음을 증명하였다.

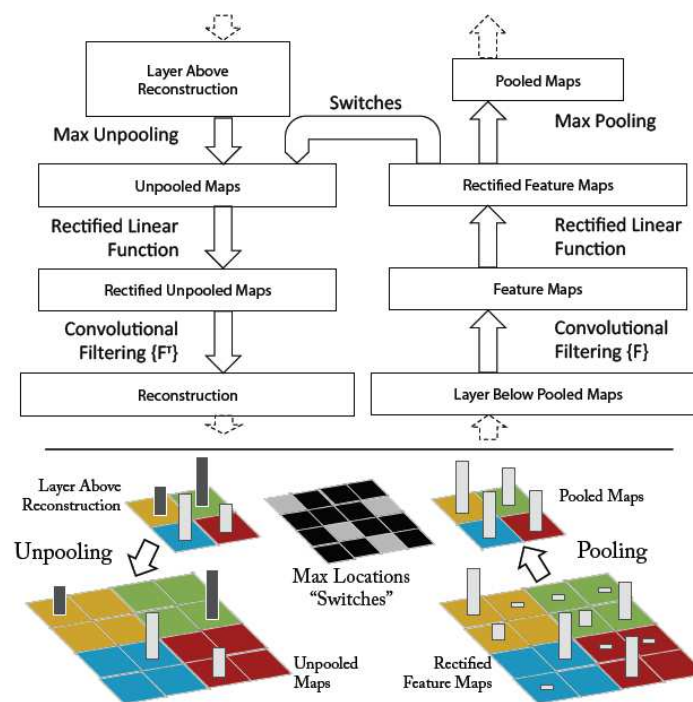


그림 2-7. ZFNet의 Deconvolution Layer(좌)와 Convolution Layer(우)[2]

[그림 2-7]에서와 같이 회선 연산 및 부차 추출을 반복하는 과정에서 추출되는

강한 신호가 원본 영상의 어떤 부분에 대응되는지를 알 수 있도록 위치정보를 Switch라는 개념으로 저장한다. 그 후 Deconvolution 과정을 통해 원본 영상에서 어떤 신호가 가장 강한 신호이며, 회선 신경망이 어떤 부분의 특징을 강하게 인식하고 학습하는지 알 수 있도록 하였다. 이 방법은 회선 신경망의 구조를 분석하는데 많은 도움을 주게 되었다.

C. GoogLeNet




그림 2-8. GoogLeNet의 구조[3]

2014년부터 회선 신경망의 성능을 높이기 위해 아주 깊은 층을 가진 신경망들이 발표되었다.[3, 4] ILSVRC 2014에서 우승한 GoogLeNet[3]은 망의 깊이를 22층으로 구현한 회선 신경망이다. 하지만 깊은 망의 경우 학습이 되지 않는 자유 파라미터(Free Parameter) 문제와 과적합(Overfitting) 문제가 발생하게 되는데 Christian Szegedy 외 8인은 이를 해결하기 위해 [그림 2-8]과 같이 Inception이라는 새로운 구조를 제안한다. Inception은 같은 층에 서로 다른 크기의 회선 필터와 1×1 회선 연산을 사용하여 다양한 스케일의 특징을 추출하고 차원 및 연산량 감소를 실현하여 높은 성능과 효율적인 학습 속도를 동시에 확보한 모듈이다.

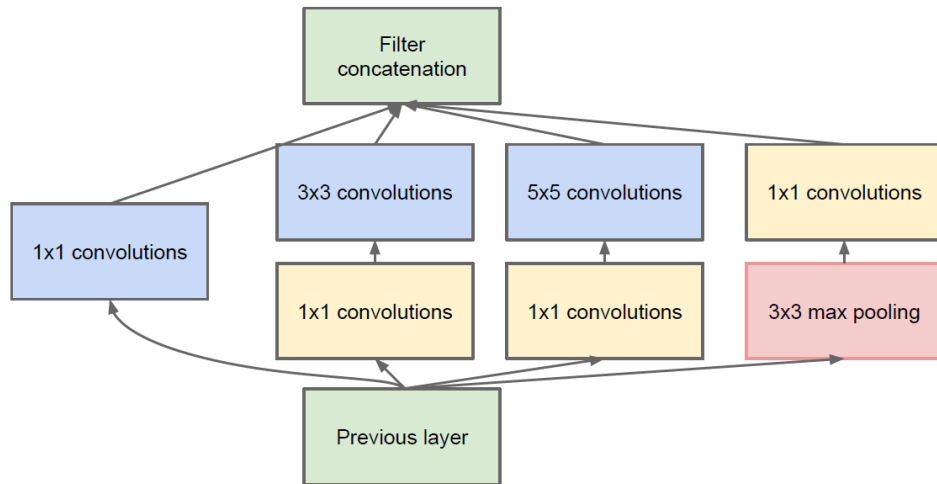


그림 2-9. Inception 모듈[3]

원본 영상의 어떤 작은 영역(Receptive Field)에서 보다 다양한 특징을 추출하기 위해 여러 크기의 회선 필터를 병렬적으로 활용하려 하였으나 회선 연산은 연산량에 있어 비싼(Expensive) 연산이기 때문에 깊은 구조의 신경망에서는 문제가 될 수 있다. 이를 해결하기 위해 Inception 모듈에서는 먼저 1×1 회선 연산을 이용하여 Feature Map의 개수를 감소 시키는 방법을 이용해 여러 스케일의 Feature를 추출 하면서도 연산량이 늘어나는 문제를 방지하였다. 이러한 방법으로 아주 깊은 구조의 신경망을 구현할 수 있었다.

GoogLeNet에는 총 9개의 Inception 모듈이 적용되었고 망의 깊이는 AlexNet에 비해 훨씬 깊으면서도 자유 파라미터는 12배 가량 적은 수준이다. 이 구조를 이용하여 ILSVRC 2014에서 Top-5 오차율 6.7%의 우수한 성적을 달성하였다.

D. 회선 신경망을 이용한 영상 인식에 관한 연구

ILSVRC 대회 외에도 회선 신경망의 높은 인식률을 이용한 객체 인식과 분류에

관한 많은 연구가 선행되었다. Gong Cheng 외 2인은 인식하고자 하는 객체 사이에 유사도가 큰 경우와 사물이 다양한 각도로 회전하는 경우에도 강한 인식 성능을 얻는 방법을 연구하였고[6], Tianjun Xiao외 5인은 객체 단위(Object-level) 분류기와 파트 단위(Part-level) 분류기를 혼합하여 미세 차이를 인식하는 방법에 관한 연구를 진행했다.[7] 신후창 외 8인은 의료 CT 영상에서 림프절의 양성, 음성 진단 및 간질성 폐 질환을 진단하는 방법에 관한 연구와 학습된 모델을 유사한 도메인의 다른 문제에 적용하는 전이 학습(Transfer Learning)에 관한 연구를 진행했다.[8, 9]

전체 영상을 대상으로 객체를 인식하는 방법 외에 회선 신경망을 이용하여 영상 내의 여러 객체를 탐지하는 방법에 관한 연구도 많이 발표되었다.[10, 11, 12, 13, 14]

제3장 연구 방법

3-1. 가성 불량 검출 모델 제안

전자제품 제조의 관점에서 불량 검사 공정은 반드시 높은 검출 성능을 확보해야만 한다. 검출되지 못한 불량품의 유출은 큰 손실을 발생시키기 때문에 가성 불량이 많이 발생 하더라도 진성 불량이 양품으로 통과되는 경우를 줄이는 것이 더 중요하다. 만일 불량 제품이 즉시 검출되지 못하고 다음 공정으로 투입된다면 추가로 소모된 자재 비용, 작업 공수 등의 손실 비용이 증가하게 되고 시장으로 유출된다면 유통 비용, A/S 비용 등의 추가 손실이 발생하며 나아가 제품 및 회사의 신뢰도에도 영향을 줄 수 있다. 그러므로 불량을 발생 즉시 검출하는 것이 가장 손실 비용을 줄이는 방법이며 특히 SMT 제조 공정은 전자 제품 생산의 시작점이라고 할 수 있는 공정이므로 다른 공정에 비해 높은 불량 검출 성능이 더욱 중요시 된다.

AOI는 오랜 기간 불량 검사 공정에 사용되어 왔고 불량 검출을 위한 많은 알고리즘과 경험이 집약된 설비이다. 검사 공정에서 필요로 하는 옵션과 높은 진성 불량 검출 성능을 갖고 있지만 단점으로는 많은 가성 불량이 발생하는 문제가 있다. 발생한 가성 불량들은 육안 검사 공정으로 전송되어 전문 검사 인력에 의한 불량 재판정이 이루어지며 이 과정에서 불량 재판정의 공수와 검사 인력 유지 비용이 발생한다. 따라서 본 논문에서는 실제적인 생산 라인에 적용을 위해 AOI의 진성 불량 검출 성능은 유지한 채 가성 불량 발생의 문제점을 보완하는 방향으로 심층 회선 신경망을 적용하고자 한다.




그림 3-1. AOI에서 수집되는 부품 영상 예시

먼저 AOI로부터 수집 할 수 있는 데이터는 [그림 3-1]과 같이 부품(Component) 레벨의 영상과 부품 ID이다. SMT 생산 라인은 하나의 라인에서 단일 제품만 생산하는 경우도 있지만 대부분의 경우 여러 제품을 생산하게 된다. 서로 다른 제품의 경우 투입되는 PCB, 실장되는 부품의 종류와 수, 배치, 방향 등이 다르다. 가성 불량 판정을 위해 학습 된 모델을 사용하는 측면에서는 제품 단위로 모델을 학습시키는 것이 편리하지만 제품의 구성이나 사양이 변경되는 경우 다시 데이터 수집과 학습을 진행해야 하는 단점이 있다. 반면 서로 다른 제품의 경우에도 부품은 공용화 되어 있는 경우가 많고, 신제품을 생산하는 경우에도 완전히 새로운 부품이 장착되는 경우는 적기 때문에 모델의 관리와 운영 측면에서는 부품 단위로 모델을 학습시키는 것이 유리하다.

부품 단위로 모델을 학습시키는 경우 다음의 상황을 고려해야 한다. 대부분의 AOI에서 불량이 검출되는 경우 해당 부품의 영상과 부품 ID가 함께 생성되지만 간혹 설비의 설정상의 이유로 영상만 생성되는 경우가 발생하기도 한다. 이러한 경우를 대비하여 본 논문의 제안 모델에서는 두 종류의 회선 신경망 분류기를 구현한다. 하나는 DefectNet으로 불량 유형을 인식하기 위해 학습된 신경망이고 다른 하나는 ComponentNet으로 부품 유형을 인식하기 위한 신경망이다. 입력 영상이 부품 ID와 함께 입력으로 제공되는 경우 바로 DefectNet을 이용하여 가성

불량 여부를 판단하고, 부품 ID가 제공되지 않는 경우에는 ComponentNet을 이용해 부품 ID를 판단한 후에 다시 DefectNet의 입력으로 전달하는 방식을 제안한다. 제안 모델의 추가적인 안전장치로 DefectNet과 ComponentNet의 예측 결과가 기준 확률(ρ) 이하인 경우 육안 검사 공정으로 전송하는 방식을 적용하여 위험 부담을 줄이고 육안 검사로 전송된 영상은 별도의 데이터베이스를 구축하여 향후 모델 학습에 다시 사용하여 모델의 예측 성능을 보완한다. 여기서 기준 확률(ρ)은 생산 라인의 관리 기준에 의거하여 적절히 선택하도록 한다. 전체 제안 모델의 구성도는 [그림 3-2]와 같다.

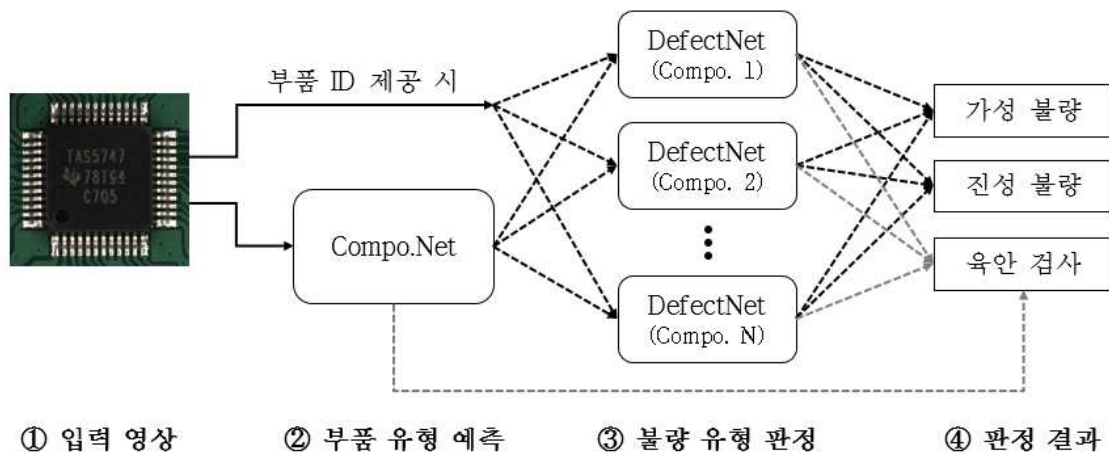


그림 3-2. 제안 모델의 불량 판정 프로세스

기존 AOI의 운영을 유지한 채 제안한 가상 불량 검출 모델을 이용하여 2차 불량 판정을 실시 함으로써 진성 불량 검출 성능은 그대로 유지하면서 가상 불량 발생률을 효과적으로 낮출 수 있을 것으로 예상된다.

3-2. 심층 회선 신경망 모델 선정

심층 회선 신경망 모델 선정에서는 판정 정확도와 학습 속도를 함께 고려한다. 일반적으로 인공신경망은 깊은(Deep) 구조를 가질수록 성능이 높아지고 필요한 학습 데이터의 양과 학습에 소요되는 시간이 증가하는 것으로 알려져 있다. 하지만 일반적인 제조 라인에서는 연구 실험실과 같은 고사양 PC를 구비하기 어려운 환경이기 때문에 보통 사양의 PC에서 CPU 연산만으로 학습을 진행하는 상황을 가정하였다. 이 경우 데이터 세트가 존재하는 부품의 수만큼 DefectNet의 학습을 진행해야 하고 또 데이터가 추가로 수집되어 재학습이 필요한 경우도 발생하므로 모델의 학습 속도가 중요한 인자가 된다. 따라서 잘 알려진 뛰어난 성능의 심층 회선 신경망 모델들 중 학습 속도를 고려하여 50층의 구조로 이루어진 Residual Network[5]와 Inception V3[15] 모델의 사용을 제안하고 선정한 모델들의 구조에 대해 살펴본다.

A. Residual Network




그림 3-3. Residual Network의 구조[5]

[그림 3-3]은 Kaiming He 외 3인이 개발한 Residual Network(이하 ResNet)

모델의 기본 구조(상)와 일반적인 회선 신경망의 구조(하)를 나타낸다. ResNet은 Residual Learning 기법을 적용한 152층의 아주 깊은(Ultra-deep) 구조로 ILSVRC 2015에서 1위를 차지한 신경망이며, 3.57%의 Top-5 오차율을 기록하여 훈련 받은 사람의 분류 오차율(약 5%정도)보다 더 좋은 결과를 얻었다. 이는 22층 구조의 Inception V1의 Top-5 오차율(6.7%)보다 두 배 가까이 우수한 성능이다.

ResNet은 신경망의 깊이가 깊어질수록 발생하는 기울기 사라짐(Gradient Vanishing) 문제와 가중치 파라미터의 증가로 인한 과적합 문제를 해결하기 위해 Residual Learning 기법을 적용하였다.




그림 3-4. ResNet에 적용된 Building Block[5]

Residual Learning이란 [그림 3-4]과 같이 2개의 층을 기본 블록으로 정의하고 블록의 출력에 입력을 연결하여 출력 값에서 입력 값을 뺀 나머지(Residual)를 학습하도록 한다. 식으로 표현하면 Residual Learning이 적용되지 않은 경우에 입력을 x , 원하는 최적의 출력을 $H(x)$ 로 정의할 때, Residual Learning이 적용된 후의 출력은 $H(x) - x$ 로 수정되며 신경망에서도 원하는 출력에서 입력을 뺀 나머지를 얻을 수 있는 방향으로 가중치들이 학습된다. 이렇게 구조를 수정하게

되면 신경망의 기본 블록들이 입력의 작은 변화(Fluctuation)를 쉽게 감지할 수 있게 되고 깊은 망도 최적화가 가능하게 된다. 추가로 더 빠른 훈련 오차 수렴 속도로 인해 학습 시간 또한 줄일 수 있다.

50층 이상의 ResNet은 연산 시간을 줄이기 위해 [그림 3-4]의 오른쪽 블록이 적용되었다. 처음의 1×1 회선 연산에서 입력 값의 차원(Dimension)을 감소시킨 후 3×3 회선 연산을 수행하고, 다시 1×1 회선 연산을 통해 차원을 확대시키는 방법으로 연산량과 연산 시간을 함께 개선한 구조이다. 이와 같이 ResNet은 높은 성능을 위해 깊은 망이 효과적으로 학습 될 수 있도록 설계되었고 학습 시간을 함께 고려하였기 때문에 본 연구의 실험에 사용하기 적합하다.

B. Inception V3

Christian Szegedy와 3명은 2-2절에서 살펴보았던 GoogLeNet 모델에서 연산량을 줄이면서 회선 연산을 하기 위한 몇 가지 개선사항을 추가하여 Inception V2를 거쳐 V3를 개발했다.[15]




그림 3-5. 회선 연산의 인수분해[15]

[그림 3-5]의 좌측은 큰 크기의 회선 필터를 인수분해(Factorization) 하여 작은 크기의 여러 단의 회선 연산으로 대체하는 방법이며 오른쪽 그림은 가로 혹은 세로 방향의 비대칭 회선을 사용한 인수분해 방법이다. 왼쪽 그림에서는 5×5 회선 연산이 3×3 회선 연산으로 대체되어 약 2.78배 가량 연산량이 줄어들었고 오른쪽 방법에서는 3×3 회선 연산이 1×3 과 3×1 회선으로 분리되어 연산량이 약 33% 정도 개선되었다. 이 두 가지 방법을 기존의 Inception 모듈에 적용한 것이 [그림 3-6]이다.




그림 3-6. Inception V3 모델에 적용된 Inception 모듈[15]

여기에 Feature Map의 해상도(Grid Size)를 효과적으로 줄이는 방식과 Optimizer 변경, 완전 연결 층에 배치 정규화(Batch Normalization)[16] 등의 몇 가지 방식을 더 추가하여 성능을 개선한 것이 Inception V3이다.




그림 3-7. Inception V3 모델의 구조

[그림 3-7]은 Inception V3 모델의 구조를 나타낸다. 새로운 Inception 모듈을 적용함으로써 22개의 층을 갖던 V1 구조에 비해 42개의 층으로 더 깊어진 모습을 볼 수 있다.

선정한 두 심층 회선 신경망 모델은 각각 50층과 42층의 구조로 깊이도 비슷하며 높은 성능을 유지하면서 학습 속도를 줄이는 방향으로 설계되었기 때문에 3-1 절에서 제안한 모델의 분류기로 사용하기에 적합하다.

제4장 실험

4-1. 실험 데이터(Dataset) 분류

본 실험에는 실제 SMT 제조 공정의 AOI에서 발생한 불량 영상을 사용하여 실험을 진행하였다. 실험에 사용된 불량 영상 데이터는 디스플레이 제품 제조 공장에서 4개월 간 수집하였으며 모든 데이터는 1차적으로 AOI가 불량으로 판정한 영상이다. [그림 4-1]과 같이 데이터의 라벨에는 불량 유형(가성 또는 진성, Binary Class)과 부품 ID(Multi Class)가 포함되어 있다.




그림 4-1. 부품 별 가성 불량 및 진성 불량 예시

불량 유형의 경우 가성 불량 또는 진성 불량으로 구분되는 이진 클래스(Binary Class)이다. 가성 불량은 양품이거나 허용 범위 내의 오차를 가진 양품으로 간주되는 불량이며, 진성 불량은 허용 범위를 벗어난 오차를 가진 제품의 정상 작동에 문제를 일으킬 수 있는 불량이다. 불량 유형의 분류는 전문적인 검사 작업자의 판단 기준에 따라 분류되었으며 검사 작업자마다 조금씩 다른 기준을 갖고 있을 수 있기 때문에 그로 인한 분류 오차가 포함되었다.

부품 코드의 경우 각 부품마다 서로 독립적으로 부여되고 부품을 구분하는 기준으로 사용된다. 본 연구에서는 불량이 발생한 1,149종의 부품들 중 가장 불량이 많이 발생한 60종의 부품을 대상으로 실험을 진행하였다. 모든 훈련 데이터 세트와 테스트 데이터 세트는 전체 데이터 세트에서 비복원 추출 방식으로 무작위 추출하였다.

4-2. 모델 학습 및 평가

A. 평가 지표

본 실험의 목적은 3-1절에서 제안한 가성 불량 검출 모델의 성능을 실험하여 사용 가능성을 확인하는 것이다. 따라서 테스트 데이터 세트의 오차(Loss)와 분류 정확도(Accuracy)를 가장 중요한 평가 지표로 활용하며 두 심층 회선 신경망의 성능을 비교하는 경우에는 학습에 소요된 시간을 지표로 추가한다.

본 연구에서 모델 학습은 Windows 7 운영체제, Intel Xeon E5-1620 CPU, 8GB RAM 사양의 PC를 활용하여 진행되었다. 모든 실험에서 데이터 세트의 Batch Size는 RAM 용량을 고려하여 50으로 설정하였다.

B. DefectNet 학습 (이진 클래스 분류기)

[그림 4-1]에 제시된 3가지 종류의 부품에 대해 모델 학습을 진행하였다. 첫 번째 실험은 부품A로 장착 위치, 틀어짐 정도, 뒤집힘 여부, 인쇄된 땀납의 양, 리드(Lead) 들뜸, 표면에 인쇄된 문자 등을 검사하여 불량 여부를 판정한다. 400개의 훈련 데이터와 100개의 테스트 데이터로 구분하였고 각 데이터 세트에서 가성 불량과 진성 불량의 비율은 5:5로 설정하였다. 각 모델에서 학습은 총 50회(epoch) 실행되었다.

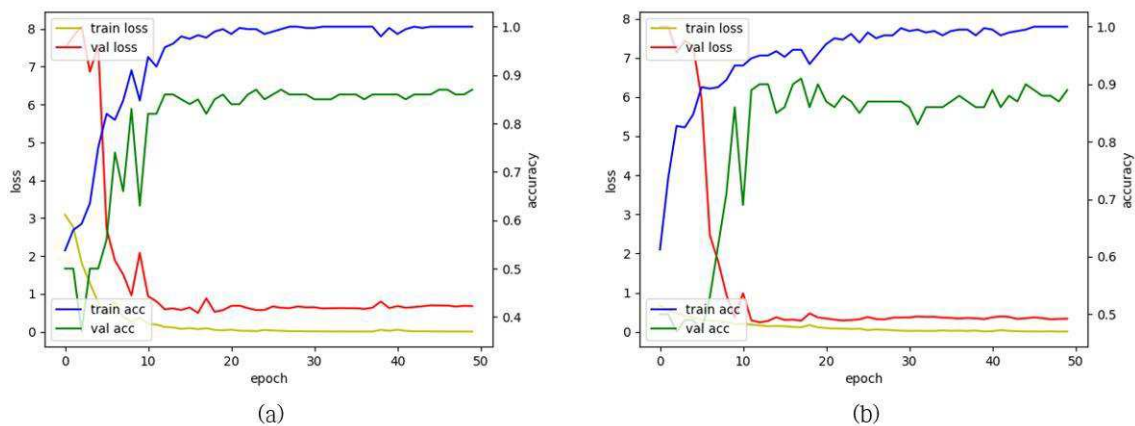


그림 4-2. 부품A의 DefectNet 학습 그래프. ResNet-50(a), Inception V3(b)

표 4-1. 부품A의 DefectNet 성능 비교

	학습 소요시간[min]	테스트 오차	테스트 정확도
ResNet-50	415.2 (50 epoch)	0.7147	88.0%
Inception V3	188.3 (50 epoch)	0.3194	90.0%

[그림 4-2]와 [표 4-1]에서 제시된 바와 같이 ResNet-50보다 Inception V3 모델의 성능이 학습 소요시간, 테스트 오차, 정확도의 모든 항목에서 우수한 것으로 나타났다. 학습 소요시간은 Inception V3 모델이 ResNet-50 대비 약 2.2배 빠르며 테스트 오차도 약 2.2배, 판정 정확도는 2% 높게 측정되었다.

이 실험으로 특히 학습 소요시간의 측면에서 Inception V3 모델이 ResNet-50 모델보다 적합하다고 판단하여 다음 모든 실험은 Inception V3 모델만을 사용하여 실험을 진행하였다.

다음은 부품B와 부품C 데이터 세트를 이용하여 모델 학습 및 성능 실험을 진행하였다. 사용된 데이터 세트의 구성은 아래 [표 4-2]와 [표 4-3]에 제시하였다. 부품C의 경우 진성 불량 데이터가 많지 않아 데이터의 비율을 고려하여 가성 불량 데이터를 무작위 추출하였다.

표 4-2. 부품B의 DefectNet 학습 및 테스트 데이터 세트 구성

	가성 불량	진성 불량	합계
훈련 데이터 수	235	334	569
테스트 데이터 수	79	112	191

표 4-3. 부품C의 DefectNet 학습 및 테스트 데이터 세트 구성

	가성 불량	진성 불량	합계
훈련 데이터 수	41	33	74
테스트 데이터 수	18	11	29

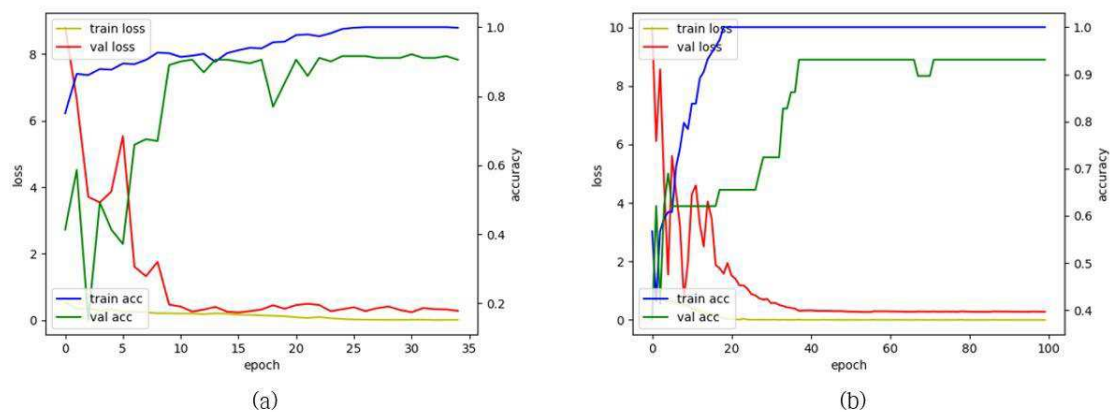


그림 4-3. 부품B(a)와 부품C(b)의 DefectNet 학습 그래프

표 4-4. 부품B, 부품C의 DefectNet 모델 성능

	학습 소요 시간[min]	테스트 오차	테스트 정확도
부품B	163.5 (30 epoch)	0.2389	92.15%
부품C	36.6 (50 epoch)	0.2988	93.10%

부품B와 부품C의 DefectNet 성능 실험에서는 Inception V3 모델을 기준으로 각각 92.15%와 93.10%의 테스트 정확도를 나타냈다. 부품A와 비교하여 더 적은 수의 데이터 세트를 사용하였음에도 높은 정확도를 나타낸 이유는 부품B와 부품C의 영상이 부품A에 비해 노이즈가 적고 원본 영상의 해상도가 높기 때문으로 분석하였다. 흥미로운 점은 모든 DefectNet의 학습 과정에서 그 성능이 어떠한 값에 안정적으로 수렴한다는 점이다. 훈련 데이터의 정확도와 오차가 100%와 0에 수렴하는 경우에도 테스트 데이터에서 오차가 증가하거나 정확도가 떨어지는 현상이 나타나지 않았다. 더 많은 실험 데이터를 사용하는 다중 클래스

분류기에서도 동일한 현상이 나타나는지 ComponentNet 실험에서 다시 확인한다.

C. ComponentNet 학습 (다중 클래스 분류기)

본 실험에서는 Inception V3 모델의 부품 유형 인식 성능을 확인한다. 부품 유형 인식은 다중 클래스 분류 문제이며 클래스 수에 따른 분류 성능 비교를 위해 불량이 가장 많이 발생하는 부품 순서로 12개, 20개, 30개, 60개 클래스의 4가지 실험을 순차적으로 진행하였다. 실험에 사용된 데이터 세트의 구성은 [표 4-5]에 제시하였다.

표 4-5. ComponentNet에 사용된 데이터 세트 구성

	12-Class	20-Class	30-Class	60-Class
학습 데이터 / Class	500	300	200	100
학습 데이터 합계	6,000	6,000	6,000	6,000
테스트 데이터 / Class	100	60	40	20
테스트 데이터 합계	1,200	1,200	1,200	1,200

클래스의 수가 적을수록 불량이 많이 발생하는 부품들로 구성되며 반대로 증가할수록 불량이 적게 발생하는 부품이 포함되므로 클래스의 수가 증가함에 따라 클래스당 데이터 수가 감소되었다. 각 실험의 전체 학습 데이터는 6,000개이며 테스트 데이터는 1,200개로 고정하였다. DefectNet과 다르게 ComponentNet은 영상의 부품 유형을 인식하는 것이 목적이므로 실험에 사용된 데이터 세트에서는 가상 및 진성 불량량의 영상이 구분되지 않고 혼합되어 있다. 각 실험에서 학습은 총

50회(epoch) 실행되었다.

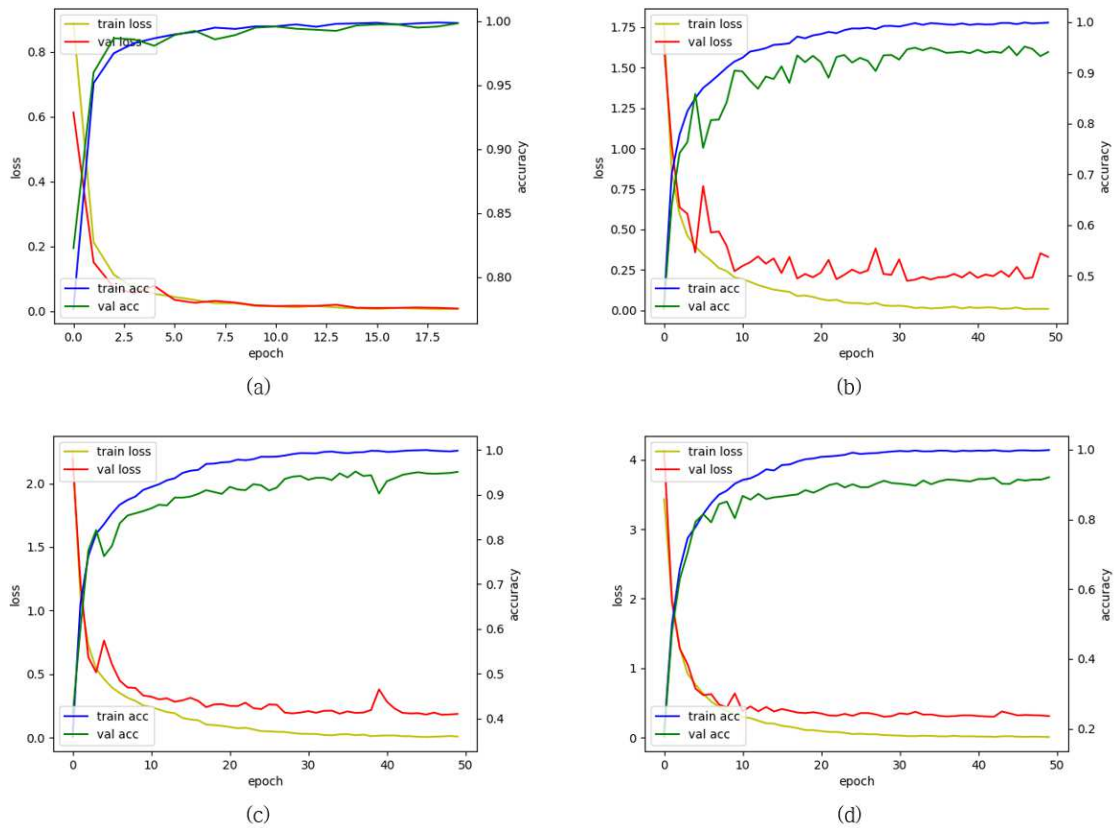


그림 4-4. ComponentNet의 학습 그래프 12-Class(a), 20-Class(b), 30-Class(c), 60-Class(d)

표 4-6. 클래스 수에 따른 ComponentNet 성능 비교

	12-Class	20-Class	30-Class	60-Class
테스트 오차	0.0081	0.1968	0.1867	0.3119
테스트 정확도	99.83%	95.17%	95.08%	92.08%

ComponentNet의 학습 결과를 [그림 4-4]와 [표 4-6]에 나타내었다. 12개 부품 분류의 경우 99.83%의 정확도를 기록하였고 20개 부품에서 95.18%, 30개 부품에서 95.08% 60개 부품에서 92.08%의 정확도를 보였다. 클래스의 수가 증가할수록 데이터 세트에 부품 ID는 다르지만 외부 형상이 비슷한 부품이 다수 포함 되므로 테스트 오차 및 분류 정확도가 떨어졌다. 외부 형상이 비슷한 부품의 경우에는 전문 검사자도 구분하기 어려우며 불량인 형태 또한 비슷하기 때문에 하나의 ID로 통합하여 모델을 학습시키는 것이 유리하다. 이 부분은 데이터 세트의 가공이 필요하기 때문에 향후 실험으로 남겨둔다. DefectNet 학습의 경우와 마찬가지로 ComponentNet 실험에서도 테스트 정확도가 안정적으로 수렴하는 모습을 보였다.

D. 제안 모델 실험

마지막 실험으로 DefectNet과 ComponentNet을 결합하여 [그림 3-2]에서 제안한 모델의 성능을 테스트한다. 이 실험에서는 4-2절의 실험 C에서 20종의 부품 영상으로 학습한 ComponentNet-20과 8종의 부품 영상으로 학습시킨 DefectNet-8이 사용되었다.

먼저 입력 영상과 부품 ID가 함께 제공되는 경우를 실험하였다. 이 경우에는 데이터가 바로 DefectNet의 입력으로 전달된다. 입력 데이터는 8종의 부품으로

이루어진 240개의 영상 데이터이며, 각 부품 별 가성 불량 15개, 진성 불량 15개로 구성된 데이터 세트이다. 모델이 분류한 결과와 실제 데이터 분류에 따른 구분을 아래 [표 4-7]과 같이 정의하였고, 기준 확률을 70%에서부터 5% 단위로 변화시키며 실험을 진행하였다. 그 결과는 [표 4-8]과 같이 나타났다.

표 4-7. 모델 분류 결과에 따른 구분

	모델 분류 결과	
	진성 불량	가성 불량
진성 불량	True Positive (TP)	False Negative (FN)
가성 불량	False Positive (FP)	True Negative (TN)

표 4-8. 기준 확률 변화에 따른 결과 비교

기준 확률(ρ)	TP	TN	FN	FP	육안 검사
0.70	94	105	9	3	29
0.75	91	102	7	3	37
0.80	90	99	7	2	42
0.85	88	97	7	2	46
0.90	82	91	6	2	59
0.95	76	80	5	2	77

두 번째로는 부품 ID 없이 영상만 제공되는 경우를 실험하였다. 입력 데이터는 8종의 부품에 대해 부품 별 무작위 추출된 60개의 영상으로 이루어진 총 480개의 영상 데이터 세트이며 ComponentNet의 입력으로 사용되었다.

입력 데이터에 대한 ComponentNet-20의 출력 결과는 [표 4-9]와 같으며 5%의 분류 오류를 보였다. 입력 영상들은 ComponentNet의 출력 결과대로 DefectNet의 입력으로 전달되었으며 그 결과는 [표 4-10]과 같이 나타났다.

표 4-9. ComponentNet-20의 출력

입력 데이터 수	분류 오류	에러율
480	24	5.0%

표 4-10. DefectNet-8의 출력

기준 확률(ρ)	TP	TN	FN	FP	육안 검사
0.75	91	102	7	3	37

ComponentNet에서 잘못 분류된 경우는 주로 외형이 유사한 부품들로부터 발생하였으며 외형이 유사한 경우 불량형의 형태 또한 유사하기 때문에 오분류 되어 다른 부품 ID의 DefectNet으로 전달된 경우에도 육안 검사로 전달된 경우를 제외하면 약 88.9%의 분류 정확도를 나타내었다.

E. 결과 및 평가

제안한 심층 회선 신경망을 이용한 가성 불량 검출 모델을 실제 생산 라인에서 수집한 데이터로 학습하고 그 성능을 비교해 보았다. 학습 그래프의 경우 비교적 많은 양의 훈련 데이터를 사용하지 않았음에도 불구하고 학습 횟수가 증가함에 따라 테스트 정확도가 안정적으로 수렴하였다. 이는 실험에 사용된 데이터 세트가 데이터 간에 작은 편차를 갖기 때문으로 분석된다.



그림 4-5. 일반적인 사물 인식에 사용되는 데이터 세트

일반적인 사물 영상의 경우 [그림 4-5]와 같이 영상 내에서 다양한 형태와 색깔, 크기, 배경, 밝기 등의 특성을 가진다. 즉 같은 사물이라 할지라도 데이터 사이의 변화(Variation)가 크고 다양한 반면 제품을 생산하는 제조 공정의 경우 생산 라인의 조건과 상태를 최대한 동일하게 유지하려 하기 때문에 부품의 크기, 모양, 조명의 밝기, 검사 지점의 좌표 등이 고정되어 있다. 따라서 같은 부품의 영상이라면 [그림 4-6]과 같이 영상 내에서 특징 정보들의 변화가 크지 않다.




그림 4-6. 가성 불량 인식 문제에 사용되는 데이터 세트

본 논문에서 실시한 실험의 결과로 심층 회선 신경망의 선정에서는 ResNet-50 모델보다 Inception V3 모델이 사용하기 적합하다는 것을 확인하였다. DefectNet의 경우 90% 이상의 분류 정확도를 보여주었고, ComponentNet의 경우에는 60종 이하의 부품에서 92% 이상의 정확도를 나타냈다. 그리고 제안한 모델의 성능 실험으로 적절한 기준 확률(ρ) 설정을 통해 실제 생산 라인에서 사용하기 적합함을

확인하였다.

실험의 결과를 바탕으로 제안 모델을 실제 SMT 제조 공정의 생산 라인에 적용한다면 AOI에서 발생하는 가성 불량률 약 90% 가량 필터링 할 수 있을 것으로 기대된다. 그리고 이는 가성 불량률로 인한 육안 검사 공정의 부담을 줄이고 검사 인력을 축소하는 효과도 가져다 줄 수 있다.

제5장 결 론

SMT 제조 공정에서 AOI는 오랜 기간 불량 검출을 위해 사용되어 왔지만 규칙 기반 알고리즘의 한계로 인해 발생하는 가성 불량은 쉽게 해결되지 못한 문제였다. 하지만 최근에 급속도로 발전되고 있는 회선 신경망을 이용한 딥러닝(Deep Learning) 방식의 영상 인식 기술은 많은 데이터로부터 사물을 구별하기 위한 특징을 스스로 학습할 수 있기 때문에 규칙 기반 알고리즘 보다 훨씬 복잡하고 유연한 분류 기준을 설정할 수 있게 해준다.

본 논문에서는 이러한 딥러닝 방식의 회선 신경망을 이용하여 가성 불량 문제를 해결하기 위한 모델을 제안하였다. 높은 인식률과 빠른 학습 속도를 위해 잘 알려진 회선 신경망들의 성능을 비교하고, 실제 생산 라인에서 수집한 데이터를 바탕으로 불량 유형 검출을 위한 신경망과 부품 유형을 인식하기 위한 신경망을 학습시키고 실제 생산 라인에 적용 가능성을 살펴보았다.

회선 신경망의 경우에는 Inception 모듈이 적용된 모델이 비슷한 깊이의 Residual Network 보다 뛰어난 성능을 갖고 있음을 확인하였고 불량 유형 분류기와 부품 유형 분류기에서 모두 90% 이상의 우수한 인식률을 기록했다. 따라서 제시한 모델을 생산 라인에 적용 함으로써 AOI의 진성 불량 검출 성능을 유지한 채 가성 불량 발생을 90% 이상 필터링 할 수 있을 것으로 기대된다.

마지막으로 살펴본 실험 데이터 세트의 특징에서 낮은 변동성(Variation)은 심층 인공신경망이 어떠한 성능에 안정적으로 수렴하도록 하는 것으로 확인되었다. 따라서 생산 라인에서 수집된 영상 데이터를 이용하여 적은 양의 데이터 세트로도 우수한 성능의 분류기를 학습 시킬 수 있으며 신경망의 깊이 또한 아주 깊은 구조를 필요로 하지는 않을 것이라 예상된다.

향후에는 회선 신경망 분류기의 성능을 높이기 위한 데이터 세트 가공 방법에 대해 연구하고 보다 최근에 발표된 다양한 회선 신경망들을 이용하여 제안 모델의 분류 정확도를 비교하는 실험을 진행할 것이다.

참고 문헌

- [1] Krizhevsky Alex, Ilya Sutskever, and Geoffrey E. Hinton. "Imagenet classification with deep convolutional neural networks." Advances in neural information processing systems. 2012.
- [2] Zeiler, Matthew D., and Rob Fergus. "Visualizing and understanding convolutional networks." European conference on computer vision. Springer, Cham, 2014.
- [3] Szegedy, Christian, et al. "Going deeper with convolutions." Proceedings of the IEEE conference on computer vision and pattern recognition. 2015.
- [4] Simonyan, Karen, and Andrew Zisserman. "Very deep convolutional networks for large-scale image recognition." arXiv preprint arXiv:1409.1556 (2014).
- [5] He, Kaiming, et al. "Deep residual learning for image recognition." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [6] Cheng, Gong, Peicheng Zhou, and Junwei Han. "RIFD-CNN: Rotation-invariant and fisher discriminative convolutional neural networks for object detection." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016.
- [7] Xiao, Tianjun, et al. "The application of two-level attention models in deep convolutional neural network for fine-grained image classification." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2015.
- [8] Shin, Hoo-Chang, et al. "Deep convolutional neural networks for computer-aided detection: CNN architectures, dataset characteristics and transfer learning."

IEEE transactions on medical imaging 35.5 (2016): 1285-1298.

[9] Pan, Sinno Jialin, and Qiang Yang. "A survey on transfer learning." IEEE Transactions on knowledge and data engineering 22.10 (2010): 1345-1359.

[10] Girshick, Ross, et al. "Region-based convolutional networks for accurate object detection and segmentation." IEEE transactions on pattern analysis and machine intelligence 38.1 (2016): 142-158.

[11] Girshick, Ross. "Fast r-cnn." Proceedings of the IEEE international conference on computer vision. 2015.

[12] Ren, Shaoqing, et al. "Faster R-CNN: Towards real-time object detection with region proposal networks." Advances in neural information processing systems. 2015.

[13] Redmon, Joseph, et al. "You only look once: Unified, real-time object detection." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.

[14] Redmon, Joseph, and Ali Farhadi. "YOLO9000: better, faster, stronger." arXiv preprint (2017).

[15] Szegedy, Christian, et al. "Rethinking the inception architecture for computer vision." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016.

[16] Ioffe, Sergey, and Christian Szegedy. "Batch normalization: Accelerating deep network training by reducing internal covariate shift." arXiv preprint arXiv:1502.03167 (2015).

ABSTRACT

Deep Convolutional Neural Networks for Detection of False Defects in SMT Manufacturing Process

Kim Jeongwook

DMC Engineering

Sungkyunkwan University

Defect inspection is a very important process in the production line. Many factories have been making automated inspection process by using optical inspectors. Optical inspector has excellent performance for true defect detection, but it has a problem of false defect because it operates with a classical rule-based algorithm.

Machine learning based deep convolutional neural networks which have been studied actively in recent years, show superior performances in the field of image recognition. In addition, various sensors and IoT(Internet of Things) technology have been applying in the production lines to make smart factory. So, the data required for deep learning are easily collected. Based on this circumstance, false defect problem is expected to be solved by using the deep convolutional neural networks and the defect images collected from the actual production lines.

In this thesis, false defect detection models that can be used in SMT(Surface Mounting Technology) manufacturing process using deep convolutional neural

networks were studied. And the false defect detection performance of the proposed model through the actually collected image data was verified.

Keywords : SMT Manufacturing Process, False Defect, Deep Learning, Convolutional Neural Network, Smart Factory

(표지측면)

碩
士
學
位
請
求
論
文

심
층
회
선
신
경
망
을
이
용
한
S
M
T
제
조
공
정
의
가
성
불
량
검
출
방
법

2
0
1
8

金
政
旭